

重庆邮电大学  
CHONGQING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

硕士学位论文  
MASTER THESIS



论文题目 基于显著锚点几何嵌入的点云配准  
方法研究

学科专业 \_\_\_\_\_  
学号 \_\_\_\_\_  
作者姓名 \_\_\_\_\_  
指导教师 \_\_\_\_\_  
学院 \_\_\_\_\_

学校代码 10617 UDC 004.93  
分 类 号 TP391.4 密级 公开

# 学位论文

## 基于显著锚点几何嵌入的点云配准方法研究

指导教师

申请学位级别 硕士 学科专业 电子信息  
答辩委员会主席 论文答辩日期 2023 年 5 月 20 日  
学位授予单位和日期 重庆邮电大学 2023 年 6 月

# **Research on Point Cloud Registration Method Based on Geometric Embedding of Significant Anchor Points**

A Master Thesis Submitted to  
School of Chongqing University of Posts and Telecommunications

Discipline      **Electronic and Information Engineering**  
Student ID  
Author  
Supervisor  
School

---

---

---

---

## **重庆邮电大学**

### **学位论文独创性声明**

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文中不包含其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在论文中以明确方式标明。本人完全知晓本声明的法律后果由本人承担。

学位论文作者签名：

日期： 年 月 日

## **重庆邮电大学**

### **学位论文使用授权书**

本人同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。

本学位论文属于：

公开论文

涉密论文，保密\_\_\_\_年，过保密期后适用本授权书。

(请在以上方框内选择打“√”)

作者签名：

导师签名：

日期： 年 月 日

## 摘要

点云是一种用于表示三维空间中的对象的数据结构。它由许多离散的点组成，可以通过激光扫描仪、三维相机或其他传感器来捕捉和记录。由于这些传感器的视野有限，因此需要将多个点云合并成一个更大的点云，或将点云与先前的点云模型对齐以进行比较或更新，这个过程就是点云配准。点云配准是计算机视觉和机器人视觉中的重要问题，它们可以用于许多应用，例如三维建模、机器人导航、虚拟现实和医学影像分析。早期的点云配准主要集中于计算机合成数据集，然而随着社会的发展，越来越多的研究开始关注真实场景下的点云配准。但真实场景中普遍存在图案重复、几何形状较弱的困难区域，这些困难区域往往会由于特征相似导致点匹配的错误，影响变换矩阵的估计结果。

为了解决该问题，本文提出了一种基于显著锚点几何嵌入的点云配准方法。该方法嵌入显著锚点与超点之间的几何结构，以增强点特征的差异性和区分度。即使在源点云和目标点云中存在大量图案重复和弱几何区域，也能分辨出相似非重叠区域找到正确的点匹配。具体来说，首先通过锚点定位模块，在源点云和目标点云中定位识别能力最强、几何信息最丰富的超点对应作为显著锚点对应。采用非最大抑制算法，保证选定的一组显著锚点在点云中稀疏分布并且具有一定的几何结构。针对显著锚点，提出了一种基于锚点距离和角度的选择性几何结构嵌入算法，用于超点特征增强。这种显著锚点与超点之间的几何一致性，可以提高几何挑战性区域的特征区分度。然后，迭代更新以增强特征和锚点位置，获得最有效的显著锚点和超点特征。最后，通过在超点对应区域内寻找最近的相邻点来实现精确的点对应。

另外，本文提出了一种基于多模态融合的锚点定位点云配准方法，该方法通过将点云的结构特征和图像的纹理特征融合以提高几何挑战性区域的特征差异性。首先本文利用对齐模块将点云和图像数据对齐以找到超点与像素之间的对应关系。然后，利用融合模块将超点与对应像素之间的特征进行融合。该融合模块将点云特征和图像特征分别投影至模态无关和模态相关的两个子空间中，并先后在两个子空间中融合两种模态特征以达到减小域差异影响和防止信息丢失的作用。

**关键词：**点云配准，几何嵌入，弱几何区域，重复图案，多模态融合

## ABSTRACT

A point cloud is a data structure used to represent objects in three-dimensional space. It consists of many discrete points that can be captured and recorded by laser scanners, 3D cameras, or other sensors. Due to the limited field of view of these sensors, multiple point clouds need to be merged into a larger point cloud, or point clouds are aligned with previous point cloud models for comparison or updating. This process is point cloud registration. Point cloud registration is an important problem in computer vision and robot vision, and it can be used in many applications, such as 3D modeling, robot navigation, virtual reality, and medical image analysis. Early point cloud registration mainly focused on computer-synthesized datasets. However, with the development of society, more and more researchers began to focus on point cloud registration in real scenes. However, the geometrically challenging areas with repetitive patterns and low geometry commonly exist in real scenes, causing failure in point matching followed by inaccurate point cloud registration.

In this thesis, this thesis propose a robust point cloud registration approach that embeds the geometry of salient anchors to enhance the discriminative ability of the point features even in the presence of a large number of repetitive patterns and low-geometry areas in the source and target point clouds. Specifically, an anchor location module is designed to locate corresponding superpoints with the most discriminative and the richest geometric information as salient anchors in the source and target. Non-maximum suppression is adopted to ensure the salient anchors are structure-preserved and sparsely distributed. With salient anchors, a selectively geometric structure embedding of anchorsuperpoint distances and angles is proposed for superpoint feature enhancement. This integration of geometry consistency between the salient anchors and superpoints can improve the distinction of features in those geometrically challenging areas. Afterwards, the enhanced features and anchor positions are updated in an iterative manner to acquire the most effective salient anchors and descriptive superpoint features. The updated features allow for accurate superpoint matches. Finally, accurate point correspondences are achieved by finding the nearest neighbour points within superpoints.

In addition, this thesis proposes a point cloud registration method based on multi-modal fusion for anchor location, which improves the feature diversity of geometrically challenging regions by fusing the structural features of the point cloud and the texture fea-

---

## ABSTRACT

---

tures of the image. First, this paper uses the alignment module to align the point cloud and image data to find the correspondence between superpoints and pixels. Then, a fusion module is used to fuse the features between the superpoints and the corresponding pixels. The fusion module projects the point cloud features and image features into two subspaces that are modality-independent and modality-dependent, and fuses the two modality features successively in the two subspaces to reduce the impact of domain differences and prevent information loss role.

**Keywords:** Point cloud registration, Geometry embedding, Low-geometry area, Repetitive patterns, Multimodal fusion

## 目 录

摘要 .....	I
ABSTRACT .....	II
图目录 .....	VI
表目录 .....	VII
第1章 绪论 .....	1
1.1 研究背景及意义 .....	1
1.2 国内外研究现状 .....	2
1.2.1 传统点云配准方法 .....	3
1.2.2 基于深度学习的点云配准方法 .....	4
1.2.3 存在的问题 .....	6
1.3 论文研究的主要内容 .....	6
1.4 论文组织结构 .....	7
第2章 点云语义分割主动域适应相关理论基础 .....	9
2.1 本章引言 .....	9
2.2 点云语义分割相关知识 .....	9
2.2.1 三维点云理论基础 .....	9
2.2.2 点云语义分割方法 .....	10
2.2.3 评价指标 .....	12
2.3 主动学习基础知识 .....	13
2.4 域适应基础知识 .....	14
2.4.1 域对齐的典型方法 .....	14
2.5 跨域点云语义分割数据集 .....	15
2.5.1 SynLiDAR .....	16
2.5.2 SemanticPOSS .....	16
2.5.3 SemanticKITTI .....	17
2.5.4 nuScenes .....	18
2.6 本章小结 .....	19
第3章 基于点云语义分割域适应的主动学习方法 .....	20
3.1 本章引言 .....	20
3.2 研究动机及贡献 .....	20

3.3 基于原型指导的主动学习方法.....	21
3.3.1 问题陈述.....	21
3.3.2 方法概述.....	22
3.3.3 源域原型构建.....	22
3.3.4 源域原型指导的数据选择.....	23
3.3.5 动态混合中间域构建.....	25
3.3.6 实验评估.....	26
3.3.7 实验结果.....	27
3.3.8 与其他主动学习方法对比.....	32
3.3.9 消融实验.....	33
3.3.10 本章小结.....	33
<b>第 4 章 基于点云语义分割域适应的主动混合策略 .....</b>	<b>35</b>
4.1 本章引言 .....	35
4.2 研究动机及贡献.....	35
4.3 基于点云语义分割域适应的主动混合策略 .....	36
4.3.1 源-目标数量平衡算法 .....	37
4.3.2 类别平衡主动混合算法.....	38
4.3.3 损失函数.....	39
4.4 实验评估 .....	39
4.4.1 实验设置.....	39
4.4.2 实验结果.....	39
4.4.3 消融对比实验.....	43
4.5 本章小结 .....	46
<b>第 5 章 总结与展望 .....</b>	<b>47</b>
5.1 主要结论 .....	47
5.2 研究展望 .....	47
<b>参考文献 .....</b>	<b>49</b>
<b>作者简介 .....</b>	<b>56</b>
1. 攻读学位期间的研究成果 .....	56
(一) 发表的学术论文和著作.....	56
(二) 申请(授权)专利.....	56
(三) 参与的科研项目及获奖.....	56
<b>致 谢 .....</b>	<b>57</b>

## 图目录

图 1-1 不同时间同一场景的点云与图像对比 .....	1
图 1-2 端到端的点云配准方法流程图 .....	4
图 1-3 基于对应关系的点云配准方法流程图 .....	5
图 2-1 3D 点云 .....	10
图 2-2 主动学习 .....	13
图 2-3 域适应 .....	14
图 2-4 SynLiDAR 数据集 <sup>[45]</sup> .....	16
图 2-5 SemanticPOSS 数据集 <sup>[46]</sup> .....	17
图 2-6 SemanticKITTI 数据集 <sup>[47]</sup> .....	18
图 2-7 nuScenes 数据集 <sup>[48]</sup> .....	19
图 3-1 基于点云语义分割域适应的主动学习方法框架 .....	22
图 3-2 源域原型构建 .....	23
图 3-3 源域原型指导的数据选择 .....	24
图 3-4 动态混合中间域构建 .....	26
图 3-5 第三章 SynLiDAR→SemanticKITTI 分割可视化图 .....	28
图 3-6 第三章 SynLiDAR→SemanticPOSS 分割可视化图 .....	29
图 3-7 第三章 SemanticKITTI→nuScenes 分割可视化图 .....	30
图 3-8 第三章 nuScenes→SemanticKITTI 分割可视化图 .....	31
图 4-1 第四章不同主动学习在多个混合比例下的对比结果 .....	44

## 表目录

表 3-1 第三章方法与其他域适应方法在 SynLiDAR→SemanticKITTI 数据上 的比较 .....	27
表 3-2 第三章方法与其他域适应方法在 SynLiDAR→SemanticPOSS 数据上 的比较 .....	28
表 3-3 第三章方法与其他域适应方法在 SemanticKITTI→nuScenes 数据上的 比较 .....	30
表 3-4 第三章方法与其他域适应方法在 nuScenes→SemanticKITTI 数据上的 比较 .....	31
表 3-5 SAPL .....	32
表 3-6 本章的主动学习方法与其他传统主动学习方法在结合 Mixing 后的对 比 .....	33
表 3-7 第三章方法消融实验 .....	33
表 4-1 第三章方法与其他域适应方法在 SynLiDAR→SemanticKITTI 数据上 的比较 .....	40
表 4-2 第三章方法与其他域适应方法在 SynLiDAR→SemanticPOSS 数据上 的比较 .....	41
表 4-3 第四章方法与其他域适应方法在 SemanticKITTI→nuScenes 数据上的 比较 .....	42
表 4-4 第三章方法与其他域适应方法在 nuScenes→SemanticKITTI 数据上的 比较 .....	43
表 4-5 第四章方法与其他 Mixing 方法对比 .....	43
表 4-6 SAPL .....	45
表 4-7 第四章方法消融实验 .....	45

## 表目录

---

# 第1章 绪论

## 1.1 研究背景及意义

近些年来，计算机视觉的发展让我们的生活越来越便利。与此同时，随着我国信息化水平和自动化进程的不断提高与推进，国家对计算机视觉的应用和发展也提出了更高要求。相比于二维图像，三维点云数据能更加清晰的表示我们所处的三维世界。图 1-1 显示了两对激光雷达点云和图像的例子，它们分别取自于不同时间的同一场景。可以清晰的观察到，点云的几何结构在光照和季节变化的情况下能够保持基本不变，而图像的变化使得人眼也难以分辨出这对图像来自于同一场景。由于点云数据具有光照不变性，能够有效避免图像处理过程中的问题，因此越来越多的研究人员开始研究点云并从中受益。但是三维视觉传感器的视野范围是有限的，因此为了感知全局的环境，在应用中经常需要将若干不同位置采集的点云数据对齐到世界坐标系下。因此，点云配准已成为许多任务的基础问题，近年来备受关注。

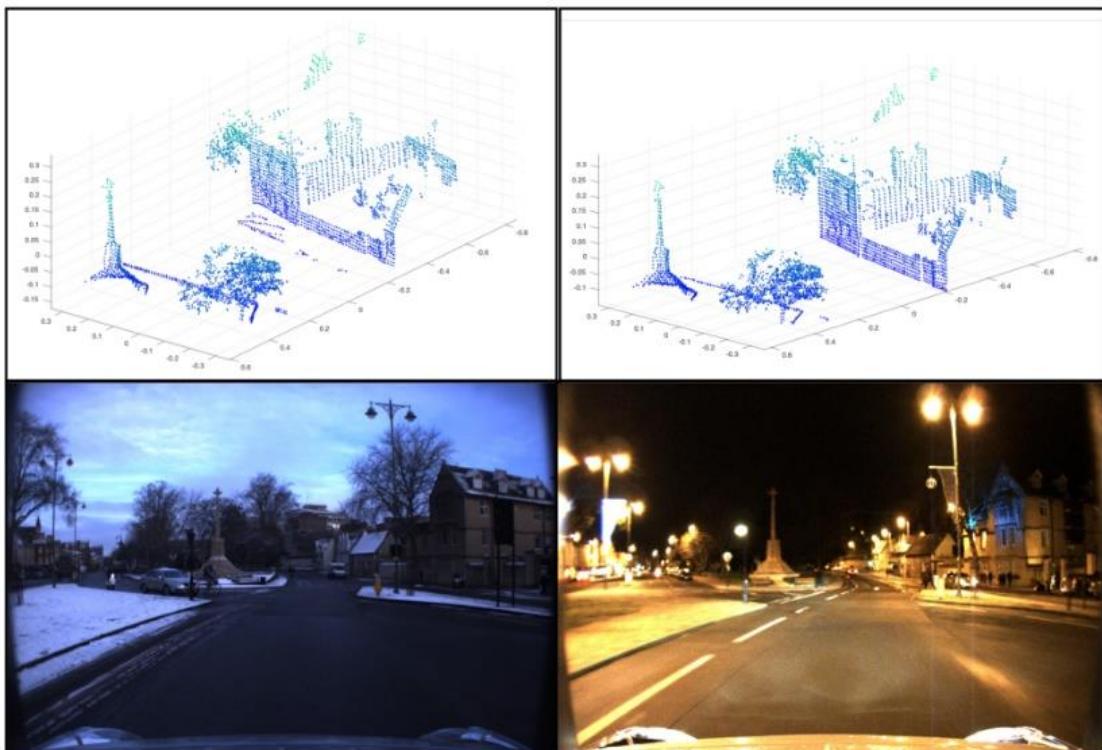


图 1-1 不同时间同一场景的点云与图像对比<sup>[1]</sup>

Fig. 1-1 Comparison between point cloud and image of the same scene at different time<sup>[1]</sup>

在医疗领域，使用点云配准能够将患者的器官及内脏等组织融合成一个整体

构建三维模型，辅助医生诊断。在文物修复领域，研究人员能够对大型文物多次扫描后将其配准生成完整的文物模型，不仅能够存储文物的三维数据以实现文物的数字化存储，还能够为后续文物的保护和修复提供可靠的数据<sup>[2]</sup>。在工业领域，点云配准是逆向工程的重要一环，能够为研究人员提供产品模型的三维数据<sup>[3]</sup>。更重要的是，点云配准是许多机器人任务的关键组成部分，是机器人对环境感知的重要一环<sup>[4]</sup>。在同时定位与建图（Simultaneous Localization And Mapping, SLAM）中，点云配准可以构建用于自动驾驶的路径规划和决策的三维地图<sup>[5]</sup>。点云配准也广泛应用于位置识别，它能够将实时的三维视图匹配到所属的三维地图中，以实现机器人对自身位置的定位<sup>[6]</sup>。同时点云配准在机器人的姿态估计中也发挥着不可或缺的作用。通过对齐视图与环境，可以获取机器人手臂的姿态信息，进而决定下一步该如何移动以抓取物体<sup>[7]</sup>。

点云配准是三维图形学研究的一个重要研究课题，也是计算机视觉的重要分支，其目的是将两个具有部分重叠区域的点云，经过一个变换矩阵在同一个坐标系下对齐。早期，不少学者提出了许多不同的方法来解决点云配准问题，这些方法主要针对于实验室理想环境下的合成数据集，而这些数据集也往往由单一的物体模型而不是场景构成。随着社会的发展，这些方法已经不能够满足生产生活需要。近年来越来越多的工作开始关注真实环境下的点云配准，其中基于深度学习的点云配准方法有着突出的表现。最近，针对低重叠率情况的点云配准得到了学界的广泛关注。所谓低重叠率的点云配准指的是将两个至多只存在 30% 重叠区域的点云进行对齐。相比于一般情况的点云配准，低重叠率的点云对之间存在许多相似非重叠区域，这会很大程度上增加特征搜索寻找正确点对应的难度，导致大量非匹配区域的误匹配。由此可见低重叠情况下的点云配准的研究重点在于如何将点的对应关系聚集在重叠区域和如何增加相似区域的特征差异。

综上所述，点云配准是处理点云数据的一项基本任务，是推进自动化进程的关键一环，在生产生活中扮演着重要的角色。因此，研究点云配准算法，提高配准精度和减少算法时间复杂度具有重大的研究价值。同时，随着近年来人工智能深度学习的快速发展，基于深度学习的点云配准方法也取得了巨大成功。本文通过对现有方法研究进行分析并改进，提高在低重叠度的情况下点云配准算法的成功率。

## 1.2 国内外研究现状

本节将从传统点云配准方法和基于深度学习的点云配准方法两个方向介绍点云配准方法的研究现状。其中传统点云配准方法早在上世纪 90 年代就得到了初步发展，而后在研究人员的不懈努力下传统方法的点云配准现在已经广泛应用于工

业生产领域。随着近些年来的人工智能的发展，将点云配准与与深度学习融合也逐渐受到越来越多的研究人员的关注，并且其性能上已经超过传统的点云配准方法。

### 1.2.1 传统点云配准方法

迭代式最近点法<sup>[8]</sup> (Iterative Closet Points, ICP) 是传统点云配准方法中最典型的一类，它由 BESL 等人在 1992 年提出。ICP 方法通过计算源点云和目标点云原始点之间的欧氏距离，以最临近点作为对应点确定两点云间点的对应关系。然后，在已知点的对应关系时，通过基于奇异值分解法求解两点云之间的变换矩阵，并进行单次对齐。重复上述两个步骤直至满足预设要求完成整个配准过程。当源点云与目标点云之间具有良好的初始位姿时，ICP 方法可以取得良好的配准结果。但是，当二者之间的距离较大时，该算法往往会在局部最优点处收敛，导致最终的结果不能满足实际生产生活需要。文献 [9] 提出一种模拟退火算法将 ICP 算法中根据点到点的距离确定的“硬”匹配关系转化为一种“软”匹配方式。这种方法虽然不能完全避免局部最优解问题，但是能够使算法在一定程度上得到缓解。YANG 等人<sup>[10]</sup> 为了解决上述问题，提出一种全局最优的迭代式最近点算法 (Globally Optimal Iterative Closet Point, Go-ICP)，其基本思想是通过分支界定法跳出局部最优解，以实现全局最优解，但与此同时算法的速度严重下降。

基于图的配准是另一类常见的方法，它主要是寻找更加准确的对应关系。相比于 ICP 方法中直接选取最邻近点作为对应点，基于图的配准方法将同时考虑点和边的关系。具体而言，图匹配算法不仅要求匹配点的点相似度高，而且要求节点之间的连线即边的相似度也要高。这种关系能够找到更准确的对应关系，而精确的对应关系有助于更好的变换估计。图匹配的优化属于二次分配问题，是一个典型的 NP 难问题，解决思想主要采取近似策略逼近。文献 [11] 和文献 [12] 采用线性规划来解决图匹配问题。文献 [13] 则将较大的相似矩阵分解为若干较小矩阵，这些矩阵对每个图的局部结构和相似性进行编码，解耦节点和边之间的相似性，使得求解过程简化。LERDEANU 等人<sup>[14]</sup> 提出了一种谱松弛的方法来近似二次分配问题，它指出正确的对应能够形成强关联的集群，而错误的对应只是一种偶然，因此不太可能产生强关联的簇，根据这一特性能够有效找出正确的对应关系。

高斯混合模型 (Gaussian Mixture Models, GMM) 是另一种常见的点云配准方法，它的核心思想是将配准问题中变换估计问题转化为求解点云数据的最大似然估计问题。任意两点之间的对应关系，将由原来的“硬”匹配转化为了由置信度表示的“软”匹配，但也因此其时间复杂度大大增加了。JRMPC 等人<sup>[15]</sup> 提出了一个 EM 算法，它估计了 GMM 参数以及将每个独立集合映射到“中心”模型上的旋转和平移。文献 [16] 通过最大似然估将源点云数据拟合到目标点云。使源点云作为

一个整体移动，以保持点集的拓扑结构。通过对具有刚性参数的 GMM 质心位置的重新参数化来施加一致性约束，并推导出 EM 算法的最大步骤的封闭解。文献 [17] 提出了一种新的凸包索引高斯混合模型。该模型通过计算每个点集凸包上的加权高斯混合模型响应来工作。

传统的点云配准算法的优点有两个方面：（1）严格的数学理论可以保证算法的收敛性；（2）不需要训练数据。然而这类方法的局限性也较为明显：ICP 算法需要一个较好的初始位置才能有良好的表现，这在真实场景下尤其是低重叠情况下难以达到要求；这类方法对数据的离群值、噪声和点云密度等特点较为敏感，在真实场景下的表现远没有在合成数据上的表现好。

### 1.2.2 基于深度学习的点云配准方法

基于深度学习的点云配准方法大致可以分为两类：端到端的点云配准方法和基于对应关系的点云配准方法。

#### 1.2.2.1 端到端的点云配准方法

文献 [18] 提出的 PointNetLK 可以被认为是一个可学习的函数。因此，将用于图像对齐的经典视觉算法 Lucas-Kanade<sup>[19]</sup> (LK) 算法与其相结合，并融合为一个循环深度神经网络。文献 [20] 赋予 PPF-FoldNet 自动编码器 (Auto Encoder, AE) 一个姿态差异结构，其中两者之间的差异产生特定于姿态的描述符。在此基础上，引入了相对姿态估计网络 RelativeNet，为关键点分配对应特定的方向。最后，利用一个简单而有效的假设-验证算法来快速预测和对齐两个点云。FMR<sup>[21]</sup> 借鉴了 PointNetLK 的思想，利用刚性变换的可逆特性，采用编解码器结构监督全局特征。文献 [22] 提出了一种基于全局特征的迭代网络 OMNet，用于部分重叠点云的配准。OMNet 以由粗到细的方式学习掩码来拒绝非重叠区域，这将部分重叠的配准转换为相同形状的配准。此外，它提出了一种更实用的数据生成方式，其中 CAD 模型对源点云和参考点云进行两次采样，避免了普遍存在的过拟合问题。

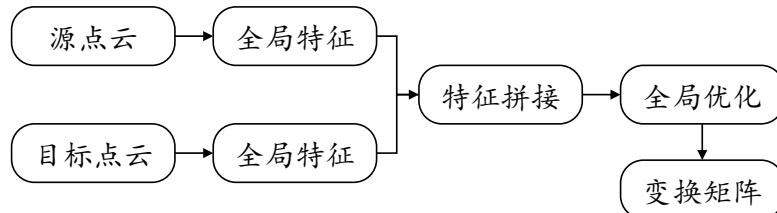


图 1-2 端到端的点云配准方法流程图

Fig. 1-2 Flowchart of the end-to-end point cloud registration

### 1.2.2.2 基于对应关系的点云配准方法

基于对应关系的配准方法主要集中在四个方面：特征提取、关键点检测、异常值去除和位姿估计。QI 等人先后提出了 PointNet<sup>[23]</sup> 和 pointnet++<sup>[24]</sup>。这两种方法虽然为点云的特征提取提供了参考，但都没有考虑点云的几何结构特征。文献 [25] 提出了一种利用弱监督学习三维特征检测器和描述子进行点云匹配的 3DFeat-Net。与许多以往的工作不同，该方法不需要手动标注匹配的点。相反，可以利用对齐和注意力机制从全球定位系统（Global Positioning System, GPS）标记的 3D 点云中学习特征对应关系，而无需人工标注。文献 [26] 提出了 3DSmoothNet，它利用暹罗网络架构匹配 3D 点云，并使用体素化平滑密度值表示实现全卷积层，并与局部参考系对齐以实现旋转不变性。文献 [27] 提出了一种新的神经网络模块 EdgeConv，构造了 DGCNN 来捕获点之间的拓扑信息。EdgeConv 作用于网络每一层中动态计算的图，其中包含了局部邻域信息，并可以叠加应用于学习全局形状属性。文献 [28] 提出 KPConv 来模拟二维卷积中的运算，以更好地捕获局部几何信息。文献 [29] 提出的 3DMatch 网络以体素为输入，利用三维卷积神经网络学习局部几何特征。文献 [30] 提出全卷积几何特征采用稀疏三维卷积代替传统的三维卷积来缓解点云稀疏性带来的问题。SpinNet<sup>[31]</sup> 通过估计的参考轴约束 z 轴自由度，并使用球面体素化消除 XY 平面旋转自由度，提取具有高鲁棒性的特征。文献 [32] 提出的 D3feat 在提取点云特征时使用 KPConv 组成的 U-Net 网络来检测关键点，并使用密度不变显著性评分来缓解密度对显著性的影响。文献 [33] 提出了一种点云配准模型 Predator，该模型对重叠区域进行了深度关注。与以前的工作不同，该模型是专门设计来处理低重叠的点云对的。其核心思想是在两个点云的潜在编码之间进行早期信息交换的重叠注意块，以预测哪些点不仅是显著的，而且还位于两个点云之间的重叠区域。

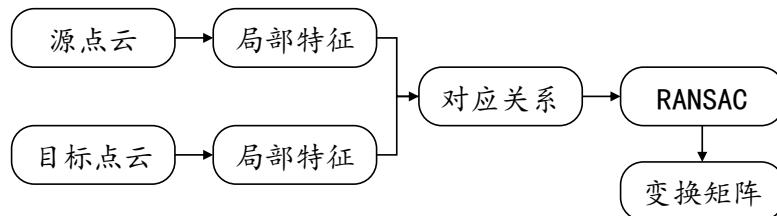


图 1-3 基于对应关系的点云配准方法流程图

Fig. 1-3 Flowchart of point cloud registration method based on correspondence

文献 [34] 提出 PointDSC，将传统方法中的空间几何一致性约束添加到网络中，利用神经网络提取对应关系的特征，通过可微的光谱匹配模块，对成对的空间一致性监督，以估计每个对应的嵌入特征的置信度。文献 [35] 提出一个由点云嵌入网

络、结合注意力模块近似组合匹配层、可微奇异值分解层三部分组成的 DCP 网络，解决局部最优和 ICP 方法中的其他问题。IDAM<sup>[36]</sup> 包括一个迭代的距离感知相似矩阵卷积模块，将来自特征和欧几里得空间的信息合并到成对点匹配过程中。这些卷积层学习基于整个几何特征的联合信息和每个点对的欧几里得偏移来匹配点，克服了通过简单地使用特征向量的内积来匹配的缺点。文献 [37] 提出了一个可微分的框架 DGR。它由三个模块组成：用于对应置信度预测的 6 维卷积网络，用于封闭姿态估计的可微分加权 Procrustes 算法，以及用于姿态细化的鲁棒基于梯度的 SE(3) 优化器。

### 1.2.3 存在的问题

点云配准方法的研究已经有了二十多年的发展并且取得了一系列的成就，特别是在深度学习流行起来之后，许多研究利用深度神经网络取得了不错的成果。然而，在最近的相关文献 [38] 中已经提到这些基于深度学习的方法的主干网络往往遇到高层特征的过度平滑和结构模糊性相关的难以区分的特征问题，这是点云配准的一个关键瓶颈。它们忽略了特征提取的一个关键因素，这可能严重影响配准精度：源点云和目标点云中每个点特征的独特性；也就是说，为了获得精确的点对应关系，以估计最优刚性变换，所需的点特征应该充分表示任何给定点附近的几何模式，同时仍然与同一点云中围绕其它点的局部结构特征有足够的差异性。然而，许多工作<sup>[39,40]</sup> 使用的骨干网络容易导致特征的超平滑和结构性的模糊问题，导致点特征难以区分。同时，将图像数据中的颜色和纹理信息引入进来通过多模态的融合，增加点特征之间的差异性是一个简单有效的想法。但是在相关研究中，许多多模态融合的方法并没有显示出比单模态的方法更加优异的表现。如何更有效的融合点云和图像两种模态的特征也是一个值得研究的问题。

## 1.3 论文研究的主要内容

本研究分别从嵌入几何结构和多模态融合两个方面入手，提高特征间的差异性，提出如下两个点云配准的方法。

1. 基于显著锚点几何嵌入的点云配准方法。首先使用共享参数的骨干网络来提取源点云和目标点云的局部特征，在特征提取过程中同时对点云下采样进行超点聚合。之后在超点层面选取若干分布于重叠区域的特征显著的锚点。同时，提出了一种新颖的基于注意力机制的几何嵌入方法。它的核心思想是将每个超点与锚点间的距离与角度信息进行编码，由于选取的多个锚点在空间中保持了一定的几何结构，因而使得这些超点与锚点之间的几何编码能够给每个超点带来各不相同的差异性特征。然后通过一个迭代优化模块，选取更加显著的锚点进一步作结

构嵌入增加特征差异性，并形成最终的超点对应。这些超点在物理空间中表示一个连续空间的区域，通过上采样能够建立超点与原始点之间的包含关系。这种由粗到细的配准方法可以在对应区域内部寻找点的对应关系而无需在全局点云中寻找，能够有效缓解特征平滑带来的误匹配，进而在变换估计中产生更加准确的变换矩阵。

2. 基于多模态特征融合的锚点定位点云配准方法。现有的点云和图像两种模态融合方法往往通过对图像进行特征提取之后，将其与点云进行简单拼接并送入神经网络完成特征融合。与这些方法不同的是，本方法采用一种对齐策略，利用相机参数将点云和图像完成点与像素的对齐之后分别提取点云特征和图像特征。并利用点与像素之间的对应关系，通过交叉注意力机制完成像素到点的选择性融合。在此过程中，两种模态的特征均会被映射至模态无关与模态相关的两个特征子空间。在模态无关子空间中，点云和图像完成模态间特征的融合，随后将融合后的特征与点云在模态相关子空间中的投影相融合。这种方法能够有效减少点云和图像之间的域间隙，使得融合过程既不过多的引入噪声也不丢失互补信息，形成最终的超点特征中。

## 1.4 论文组织结构

为了更加清晰地阐述本文的主要工作，本文结构安排如下：

第1章为绪论部分。首先对本文的选题背景和研究意义进行了介绍。然后，对国内外学者在点云配准研究领域取得的一些成就和研究进展进行了简单的陈述，并对目前点云配准方法中存在的问题进行了分析探讨。最后，对本文的主要研究做了简单的介绍，并阐述了本文的组织结构。

第2章为相关技术理论基础。首先对点云配准任务进行介绍。然后，介绍了点云配准任务中常用的用于求解刚体变换矩阵的基于SVD的线性代数法和基于RANSAC<sup>[41]</sup>的随机一致性采样法。接着，对点云配准的数据集做了详细介绍，主要包括合成数据集和真实场景数据集。最后，介绍了用于评估点云配准算法的性能的评价指标。

第3章是基于显著锚点几何嵌入的点云配准方法。首先介绍了本文提出方法的主要动机。接下来介绍了基于显著锚点几何嵌入的框架网络，介绍了如何从下采样后的超点中选取出位于重叠区域的保持一定几何结构的显著锚点。接下来介绍了如何利用自注意力和交叉注意力机制嵌入超点与超点之间以及超点与锚点之间的几何结构特征。之后对基于由粗到细框架的点云配准方法的点匹配阶段和变换估计方法做了简单介绍。接着介绍了该网络分别用来监督粗匹配阶段产生的超点

匹配结果与细匹配阶段产生的点匹配结果的两个损失函数。然后是实验部分，对实验用到的数据集，实验设置以及实验结果及分析做了详细的描述。最后对第三章进行了总结。

第4章是基于多模态的锚点定位点云配准。首先介绍了当前方法将点云与图像两种模态融合的一些问题和多模态融合之前加入对齐模块的动机。然后简要介绍了本文对点云和图像两种模态数据进行特征提取的网络结构。之后介绍了对齐模块在整个网络中的作用与功能，主要是消除在数据增强情况下点云和图像数据的错位。然后介绍了多模态融合模块，利用一个简单的映射网络将两种模态的特征在模态无关子空间进行融合，并在模态相关子空间进一步补充相关信息的过程。接下来是实验部分，从数据集的预处理，实验设计和结果分析三个方面来进行阐述。最后对本章进行了总结。

第5章是总结与展望。首先对本文所作的工作进行了总结，然后根据本文的实验结果指出了方法中存在的问题和未来的研究方向。

## 第2章 点云语义分割主动域适应相关理论基础

### 2.1 本章引言

本章节对本文研究相关的各个领域理论基础进行介绍，包含点云语义分割基础知识、主动学习基础知识以及域适应相关知识。对于点云语义分割，主要介绍常用点云表示方式，点云语义分割任务的基本任务模型以及评价指标；对于主动学习，介绍主动学习的基本概念及其流程框架；对于域适应部分，主要对域适应概念及域对齐的常见方法进行了介绍。最后，对点云语义分割域适应相关任务中常用公开数据集进行了介绍。

### 2.2 点云语义分割相关知识

#### 2.2.1 三维点云理论基础

三维点云是三维空间中离散点的集合，每个点通过坐标  $(x, y, z)$  描述位置，部分还包含颜色、反射强度等附加信息。这些点通常由激光雷达（LiDAR）、深度相机等设备采集而来，能够高精度还原物体表面的几何特征。与传统的二维图像不同，点云直接记录三维空间信息，因此在机器人导航、自动驾驶、虚拟现实等领域有不可替代的作用。如图2-1所示，点云数据根据采集场景可分为室内与室外两类。室内点云多由深度相机或近距离激光雷达获取，特点是密度高、遮挡少，适合精细建模。例如扫地机器人通过室内点云构建房间地图，避开桌椅等障碍物。室外点云则依赖车载或机载激光雷达，场景尺度大，但点云稀疏且包含动态物体。自动驾驶汽车利用这类数据识别远处的车辆、行人，但需要处理树木遮挡或雨天噪声的干扰。尽管场景不同，两类点云均需应对数据量大、无序排列和非结构化的共性挑战。点云的优势在于其真实的三维几何表达能力。例如在建筑测绘中，点云能直接输出墙壁的倾斜角度或梁柱的尺寸，而无需从二维图像中推算。同时，点云对光照变化不敏感，在黑暗环境中仍可依靠几何信息工作。然而，点云数据也存在明显缺陷。单帧激光雷达点云可能包含数十万个点，存储与计算成本高昂；传感器噪声或物体遮挡会导致数据缺失，影响后续处理。因此，在数据处理层面，点云通常经历去噪、配准、特征提取等步骤。去噪用于消除传感器误差或环境干扰产生的离群点；配准将多视角点云对齐，形成完整场景模型；特征提取则从点云中识别平面、边缘等结构，为物体检测提供基础。随着技术进步，轻量化传感器与实时处理算法逐渐成为趋势。例如自动驾驶系统需在毫秒级时间内完成点云分割，区分道路、车辆与行人。点云与其他三维表示方法各有优劣，相比网格（Mesh）模型，点云保留

原始采集数据，但缺乏明确的表面连接关系；与体素（Voxel）相比，点云内存占用低且分辨率高，但难以直接应用卷积操作。因此，一般在大规模场景中，往往更多的是选择体素方式进行点云处理。

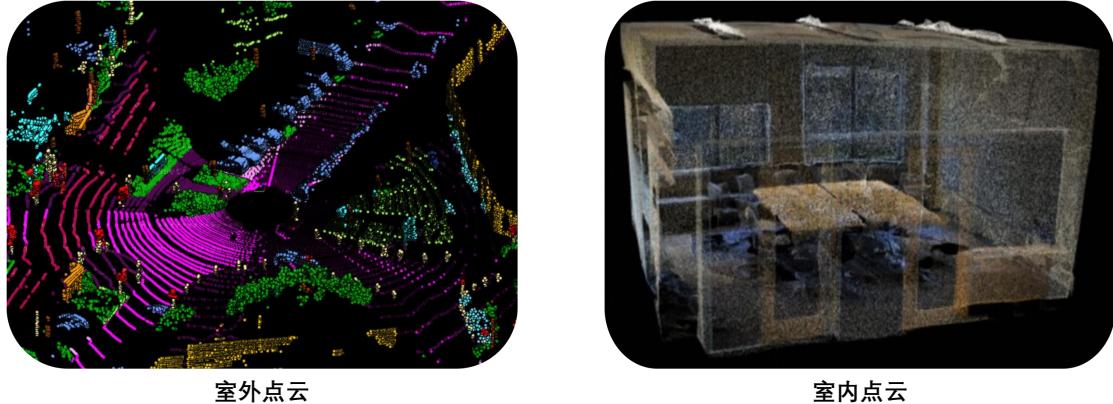


图 2-1 3D 点云

Fig. 2-1 3D point cloud

## 2.2.2 点云语义分割方法

### 2.2.2.1 目标与输入数据

点云语义分割的目标是为三维空间中的每个点赋予特定语义标签。在自动驾驶场景中区分道路、车辆、行人等类别，在室内建模中识别墙面、家具等物体。这一过程本质上是将无序的三维点云转化为带有语义信息的数据。输入的数据通常是由激光雷达（LiDAR）或深度相机采集的原始点云，其基础形式为包含  $N$  个点的坐标矩阵，形状为  $N \times 3$ ，对应每个点的三维坐标  $(x, y, z)$ 。在一些特殊的场景中，点云可能还包含颜色（RGB 值）、反射强度（LiDAR 返回信号强度）或时间戳（动态场景中的时序信息）等附加特征，此时数据维度扩展为  $N \times D$ ，其中  $D \geq 3$ 。数据预处理阶段通常会对坐标进行归一化，以消除传感器位姿的影响，并对离群点进行滤波以提高后续处理稳定性。

### 2.2.2.2 特征提取方法

特征提取是点云语义分割的核心，其目的是从原始点云中挖掘具有判别性的局部与全局特征。根据输入表示方式的不同，主流方法可分为三类：

1) 基于点的方法。此类方法直接处理原始点云，避免因体素化或投影导致的信息损失。典型代表如 PointNet++<sup>[24]</sup>，其核心思想是通过多层感知机（MLP）逐点提取特征，并通过最大池化聚合全局信息。具体而言，对于每个点  $\mathbf{p}_i$ ，模型不仅编码其自身坐标，还通过邻域查询（如 k 近邻或球查询）收集周围点集  $\{\mathbf{p}_j | j \in \mathcal{N}(i)\}$ ，

进而利用共享权重的 MLP 提取局部几何模式，如公式(2-1)所示：

$$\mathbf{F}_i = \text{MLP}(\mathbf{p}_i - \mathbf{p}_j, \|\mathbf{p}_i - \mathbf{p}_j\|_2) \quad \forall j \in \mathcal{N}(i) \quad (2-1)$$

其中  $\mathbf{p}_i - \mathbf{p}_j$  表示相对位置， $\|\cdot\|_2$  为欧氏距离。通过堆叠多个局部特征提取层，模型可逐步扩大感受野，捕获多尺度几何结构。

2) 基于体素的方法。基于体素的方法通过将点云转换为规则三维网格实现高效计算。MinkowskiNet<sup>[42]</sup> 是该领域的一个代表性方法，其核心是通过稀疏卷积网络，仅对非空体素进行计算，大幅减少内存与计算开销。稀疏卷积的表达式如公式(2-2)所示：

$$\mathbf{F}_{\text{out}}(x, y, z) = \sum_{(dx, dy, dz) \in \mathcal{K}} \mathbf{W}(dx, dy, dz) \cdot \mathbf{F}_{\text{in}}(x + dx, y + dy, z + dz) \quad (2-2)$$

其中  $\mathcal{K}$  为卷积核覆盖的偏移范围， $\mathbf{W}$  为卷积核权重。与传统三维卷积不同，稀疏卷积通过哈希表管理非空体素坐标，仅对有效位置执行计算。

3) 基于投影的方法。此类方法将三维点云投影至二维平面，复用成熟的图像处理网络。其中 RangeNet++<sup>[43]</sup> 将 LiDAR 点云转换为球面距离图像 (Range Image)，每个像素对应点的深度与方位角。投影后的二维图像通过改进的二维卷积网络提取特征，如公式(2-3)所示：

$$\mathbf{F}_{l+1}(u, v) = \text{ReLU} \left( \sum_{m, n} \mathbf{K}(m, n) \cdot \mathbf{F}_l(u + m, v + n) \right) \quad (2-3)$$

其中 ReLU 为激活函数。投影方法的计算效率较高，但可能因遮挡或投影畸变导致部分三维信息丢失。

### 2.2.2.3 分类与损失函数

在特征提取后，模型通过全连接层将  $N \times F$  维特征映射至  $N \times C$  维类别得分矩阵，其中  $C$  为类别总数。Softmax 函数将得分转换为概率分布，为每个点分配类别标签，如公式(2-4)所示：

$$P(y_i = c) = \frac{e^{\mathbf{z}_{i,c}}}{\sum_{c'=1}^C e^{\mathbf{z}_{i,c'}}} \quad (2-4)$$

其中  $\mathbf{z}_{i,c}$  表示第  $i$  个点在第  $c$  类上的得分。损失函数采用交叉熵损失，衡量预测概率与真实标签的差异，其数学表达式如公式(2-5)所示：

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log P(y_i = c) \quad (2-5)$$

式中  $y_{i,c}$  为 one-hot 编码的真实标签。

### 2.2.3 评价指标

在点云语义分割任务中，常用的评估指标有两个，一个是总体精度（Overall Accuracy, OA），另一个则是平均交并比（mean Intersection over Union, mIoU）。

总体精度通过计算正确预测点数占总点数的比例，直观反映模型的整体分类能力，其表示式如公式(2-6)所示：

$$OA = \frac{TP + TN}{TP + TN + FP + FN} \quad (2-6)$$

其中  $TP$  表示正确预测的正例， $TN$  为正确预测的反例， $FP$  为误判的正例， $FN$  为误判的反例。尽管 OA 计算简单，但在点云语义分割中，由于场景中不同类别点数差异显著，如城市道路点占比可能超过 50%，而交通灯可能不足 1%，OA 易被多数类别主导，这一缺陷使得 OA 难以真实评估模型性能。

平均交并比则通过衡量每个类别的预测区域与真实区域的重叠程度，提供更均衡的评估。对于类别  $c$ ，其交并比计算公式如(2-7)所示：

$$IoU_c = \frac{TP_c}{TP_c + FP_c + FN_c}, \quad (2-7)$$

其中  $TP_c$  为类别  $c$  的正确预测点数， $FP_c$  为误判为  $c$  的点数， $FN_c$  为漏判的  $c$  类点数。mIoU 取所有类别 IoU 的平均值，其表达式如公式(2-8)所示：

$$mIoU = \frac{1}{C} \sum_{c=1}^C IoU_c \quad (2-8)$$

式中  $C$  为类别总数，mIoU 的核心优势在于其对每个类别的平等关注，即使某一类别的点数极少，其 IoU 值仍能直接影响整体得分，从而迫使模型兼顾所有类别。

当前研究普遍以 mIoU 为核心评价指标，主要因其能够克服类别不平衡带来的评估偏差。点云数据中，高频率类别与低频率类别的点数差异可能达到数百倍，若依赖 OA 这类整体指标，模型可能仅通过优化高频类别即可获得高评分，而忽视低频类别的学习。mIoU 通过独立计算每个类别的重叠率，确保模型在各类别上的表现均被量化，从而更真实地反映其实际分割能力。此外，mIoU 对边界误差的敏感

性也优于 OA，物体边缘点的误分类会同时增加  $FP$  和  $FN$ ，导致 IoU 显著下降，而 OA 可能因整体正确率高而掩盖此类局部缺陷。

### 2.3 主动学习基础知识

主动学习作为传统机器学习中的一个分支，其核心思想是让模型在训练过程中主动选择对提升性能最有价值的数据进行标注，而非被动接受随机标注的数据。该方法的核心目的是在有限标注成本的约束下，通过主动的数据选择策略，最大化模型的性能。如图2-2所示，主动学习的流程可概括为迭代式的“选择-标注-训练”循环。首先，利用初始标注数据训练一个基础的目标模型。随后，模型对未标注数据进行推理预测，生成预测结果。基于这些预测，通过预设的选择策略，从未标注数据中筛选出对当前模型提升最有价值的候选数据。筛选出的候选数据由标注者即该领域相关专家进行标注，新标注数据与原有标注数据合并后，用于更新模型参数。这一过程持续迭代，直至标注预算耗尽或模型性能趋于稳定。流程中的核心模块包括选择策略设计以及模型更新机制，选择策略的优劣直接决定主动学习效率，常见策略包括不确定性采样、多样性采样和委员会查询。不确定性采样：选择模型预测置信度最低的样本；多样性采样：选择代表数据分布多样性的样本，覆盖不同特征空间区域；委员会查询：训练多个模型，选择各模型预测差异最大的样本。模型更新机制一般考虑如何利用这些已标注的高价值目标点来对模型进行微调以充分发挥数据与模型的潜力。

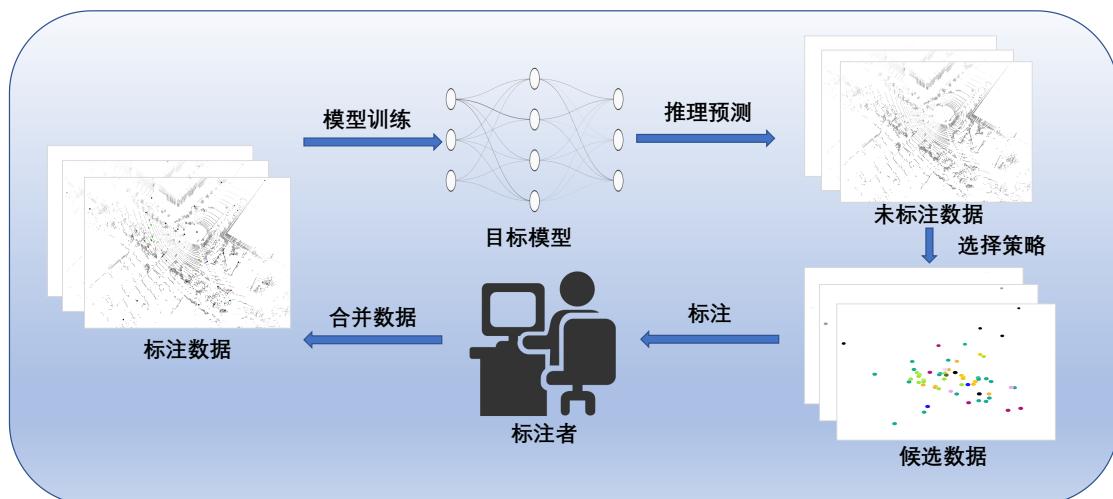


图 2-2 主动学习

Fig. 2-2 Active learning

## 2.4 域适应基础知识

域适应是机器学习中一种重要的技术，主要用于解决模型在相同任务不同数据分布场景下的泛化问题。如图2-3所示，当模型在一个数据集即源域上训练得非常好，能够正确的将数据分类，但在另一个数据集称为目标域上表现却不佳，无法对目标域中的数据进行正确的分类，而造成这一现象的主要原因是不同数据域之间分布不同，存在域间差异，从而导致模型无法对新数据域中的数据进行正确分类，而域适应的目标就是帮助模型适应目标域的数据分布，从而提升其在新数据中的性能。域适应的核心思想是找到源域和目标域之间的共同特征，并通过调整模型或数据，缩小两者之间的分布差异。造成这些差异的原因有很多，比如点云的密度、物体形状的细微变化，或者传感器采集数据的方式不同。域适应的目标就是让模型学会忽略这些差异，而专注于识别共同的特征信息。

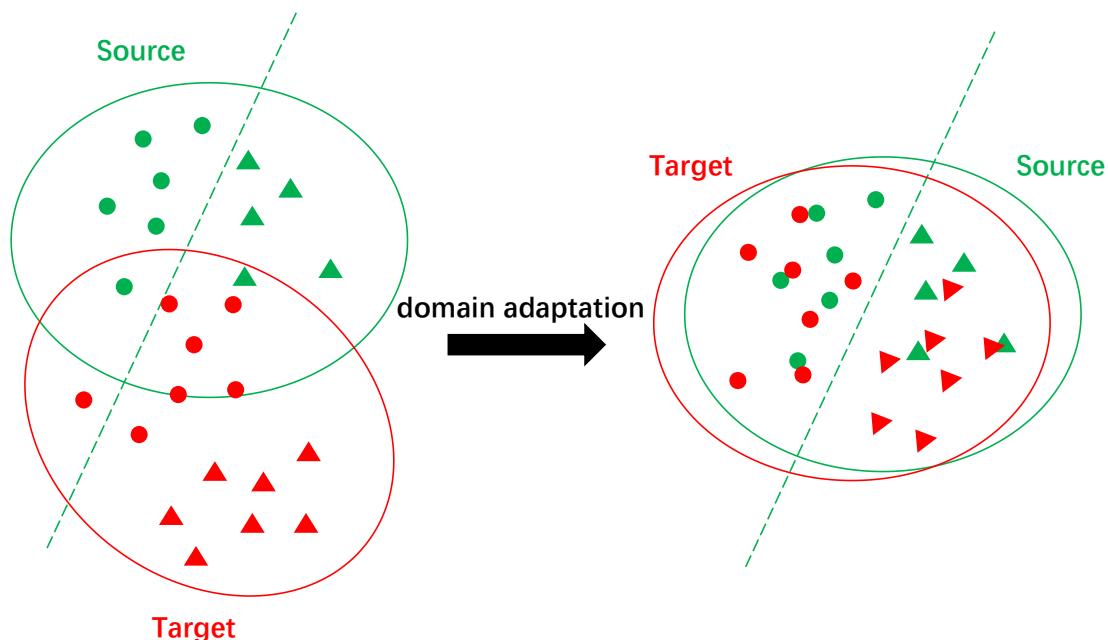


图 2-3 域适应

Fig. 2-3 Domain adaptation

### 2.4.1 域对齐的典型方法

#### 2.4.1.1 基于差异度量的域对齐

最大均值差异（Maximum Mean Discrepancy, MMD）是一种衡量两个分布之间差异的常用方法，尤其在域适应与生成对抗网络等任务中应用广泛。它的核心思想是先将数据映射到一个称为可再生核希尔伯特空间（RKHS）的高维特征空间中，再比较两个分布在该特征空间中平均嵌入（mean embedding）之间的距离。如果两

个分布越相似，它们在该空间中的平均嵌入就越接近；反之则越远。MMD 表达式如公式(2-9)所示：

$$\text{MMD}^2 = \left\| \frac{1}{N_s} \sum_{i=1}^{N_s} \phi(x_i^s) - \frac{1}{N_t} \sum_{j=1}^{N_t} \phi(x_j^t) \right\|_{\mathcal{H}}^2, \quad (2-9)$$

其中  $\phi(\cdot)$  是将数据映射到高维空间的核函数， $N_s$ ,  $N_t$  分别是源域和目标域的样本数。通过最小化 MMD，模型特征提取器  $g_\theta$  被约束以生成域不变特征。

#### 2.4.1.2 对抗式域适应

受生成对抗网络（GAN）启发，对抗训练通过域判别器  $D$  引导特征生成器  $g_\theta$  混淆域特征，其目标函数为极小极大博弈，如公式2-10所示：

$$\min_{g_\theta} \max_D \mathbb{E}_{x^s} [\log D(g_\theta(x^s))] + \mathbb{E}_{x^t} [\log(1 - D(g_\theta(x^t)))] , \quad (2-10)$$

其中  $D$  试图区分源域与目标域特征，而  $g_\theta$  试图生成  $D$  无法区分的特征。而在经典模型对抗域适应网络 DANN<sup>[44]</sup> 中，则是将对抗损失与任务损失结合，如公式(2-11)所示：

$$\mathcal{L}_{\text{DANN}} = \mathcal{L}_{\text{task}} - \lambda \cdot \mathcal{L}_{\text{adv}}. \quad (2-11)$$

#### 2.4.1.3 自训练与伪标签

自训练利用模型对目标域的预测生成伪标签，逐步迭代优化。定义伪标签为  $\hat{y}_j^t = \arg \max_c f_\theta(x_j^t)$ ，目标域损失表达是如公式(2-12)所示：

$$\mathcal{L}_{\text{self}} = \sum_{j=1}^{N_t} \mathbb{I}(\max f_\theta(x_j^t) > \tau) \cdot \mathcal{L}(f_\theta(x_j^t), \hat{y}_j^t), \quad (2-12)$$

其中  $\tau$  为置信度阈值， $\mathbb{I}(\cdot)$  为指示函数。此方法需谨慎设计阈值以避免噪声累积，常与对抗训练结合使用。

## 2.5 跨域点云语义分割数据集

虽然目前已有很多开源的点云语义分割数据集，但它们往往适用于不同的应用场景。在点云语义分割的域适应任务中，通常会选择一些流行且广受认可的特定数据集作为实验标准。本研究同时涉及合成到真实（Synthetic-to-Real）和真实到真实（Real-to-Real）两个跨域场景。其中，在合成到真实的跨域场景下，通常使用合成数据 SynLiDAR<sup>[45]</sup> 迁移至 SemanticPOSS<sup>[46]</sup> 或 SemanticKITTI<sup>[47]</sup> 等真实数据集；而在真实到真实的跨域场景中，则一般使用 SemanticKITTI 与 nuScenes<sup>[48]</sup> 两

个真实数据集进行相互迁移适应。以上所涉及的数据集均为室外数据集，接下来本小节将分别对这些数据集进行详细介绍。

### 2.5.1 SynLiDAR

SynLiDAR 是一个大规模的合成 LiDAR 点云数据集，专为促进从合成数据到真实数据的跨域语义分割研究而创建。该数据集包含超过 190 亿个逐点标注的点，涵盖 32 个语义类别，具有丰富的语义信息和高度的几何准确性。与现有的真实 LiDAR 数据集相比，SynLiDAR 的规模更大，质量更高，语义类别更丰富，且标



图 2-4 SynLiDAR 数据集<sup>[45]</sup>

Fig. 2-4 SynLiDAR datasets<sup>[45]</sup>

注更加细致和全面。SynLiDAR 的点云数据是在多个由专业 3D 设计师构建的虚拟环境中生成的，这些虚拟环境包含大量与真实世界数据在几何形状和布局上相似的物体模型。如图2-4所示，数据集中的每个虚拟场景都经过精心设计，以确保合成数据的高质量和真实性。SynLiDAR 的点云数据具有逐点标注，标注类别包括汽车、自行车、摩托车、卡车、其他车辆、行人、骑自行车者、骑摩托车者、道路、停车场、人行道、其他地面、建筑物、围栏、植被、树干、地形、杆、交通标志等，涵盖了丰富的动静态对象，适用于多种语义分割任务。

### 2.5.2 SemanticPOSS

SemanticPOSS 是一个真实世界的小规模数据集，使用 Pandora 40 线激光雷达传感器在北京大学采集，包含 2988 个扫描样本。每个扫描样本包含约 80,000 到 100,000 个点，捕捉了典型的都市户外场景。该数据集包含 13 个语义类别，为研究者提供了丰富的数据资源。在数据集划分方面，遵循先验研究的方法，将包含 500 个点云样本的 03 序列分配用于验证，而剩余的 2488 个点云样本则用于训练。在点云语义分割域适应中，将 SynLiDAR 数据集上训练的模型迁移到 SemanticPOSS 数

据集上，并将类别映射为13个共有的语义类别，包括汽车、自行车、人、骑行者、地面、建筑物、栅栏、植物、树干、杆、交通标志、垃圾桶、路锥/石块。其数据集展示图如图2-5所示。

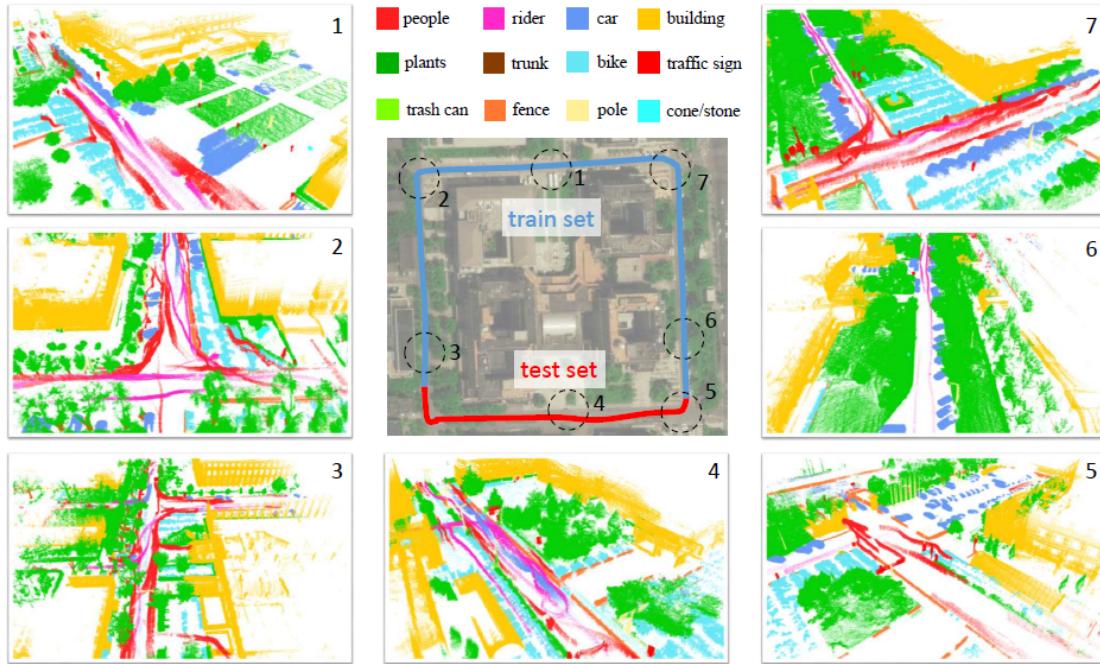


图 2-5 SemanticPOSS 数据集<sup>[46]</sup>

Fig. 2-5 SemanticPOSS datasets<sup>[46]</sup>

### 2.5.3 SemanticKITTI

SemanticKITTI是一个大规模的室外数据集，是基于真实道路场景构建的激光雷达点云数据集，可用于多种点云分割任务和语义场景补全，与SemanticPOSS相比，该数据集场景更广泛且庞大。其数据通过车载激光雷达采集，包含三维坐标与反射强度信息，但未包含颜色特征。数据集基于KITTI里程计基准扩展，通过逐点标注实现了360度全景点云的精细化语义标注，涵盖动态与静态对象19个类目标，同时包含地面与可行驶区域等特殊语义类别。如图2-6所示，数据集共由22个点云序列组成，每个序列都包含一段录制点云。其中，序列00-10和08总共提供了23201个有标注信息的点云，分别用于训练和验证；11-21提供了20351个没有标注信息的点云，用于测试。点云语义分割域适应中，将SynLiDAR数据集上训练的模型迁移到SemanticKITTI数据集上，并将类别映射为19个共有的语义类别，包括汽车、自行车、摩托车、卡车、其他车辆、行人、骑自行车者、骑摩托车者、道路、停车场、人行道、其他地面、建筑物、栅栏、植被、树干、地形、杆状物、交通标志。

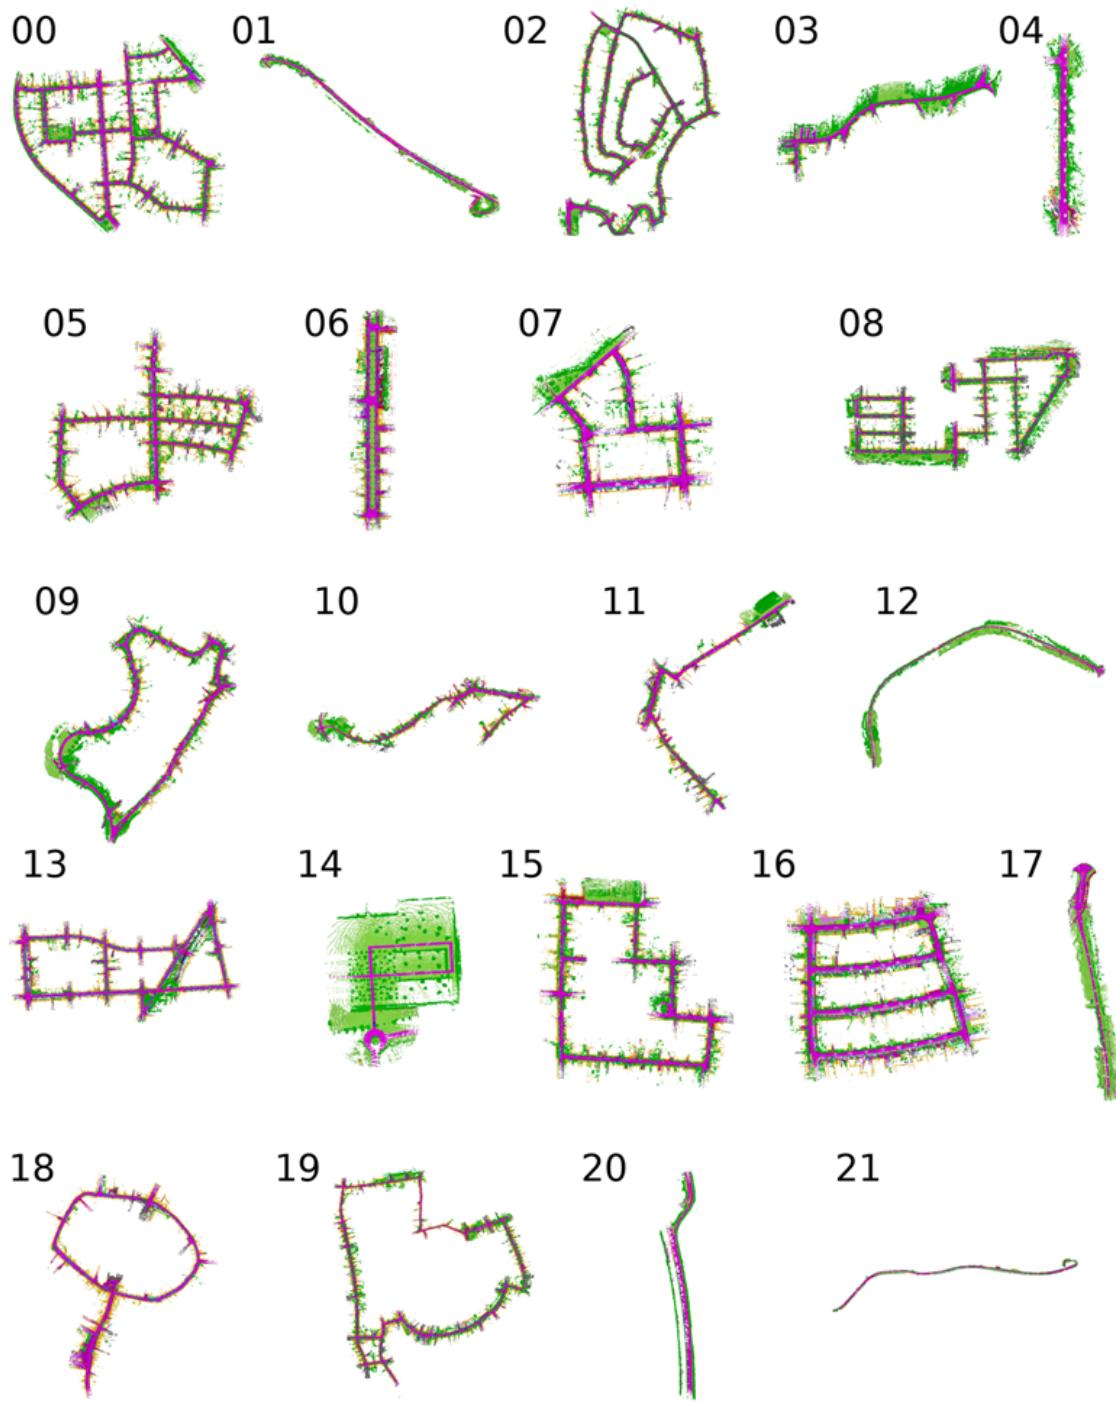


图 2-6 SemanticKITTI 数据集<sup>[47]</sup>  
Fig. 2-6 SemanticKITTI datasets<sup>[47]</sup>

#### 2.5.4 nuScenes

nuScenes 是多模态自动驾驶数据集的代表性资源，整合了激光雷达、摄像头、毫米波雷达及定位系统的同步采集数据，覆盖波士顿与新加坡的 1,000 个复杂驾驶场景。其激光雷达语义分割子集（nuscenes-lidarseg）包含约 14 亿个点云，总计

40,000 帧数据，划分为 850 个训练验证场景与 150 个测试场景。语义标注涵盖 16 类关键目标，包括自行车、公交车、轿车、工程车、摩托车、行人、卡车、拖车等交通参与者，可行驶区域、其他人造地面、人行道、自然地面等道路要素，以及障碍物、锥形路标、植被和人造物体等环境元素。类别设计注重实际驾驶场景的多样性，尤其强调对临时障碍物的精细化标注，例如锥形路标与非铺装路面，为复杂环境下的多目标感知与路径规划提供高精度数据支持。其数据集展示图如图2-7所示。在点云语义分割域适应中，SemanticKITTI 与 nuScenes 数据进行模型的相互迁移，最终将类别映射为 7 个共有的语义类别，包括车辆、行人、道路、人行道、地形、人造物体、植被。

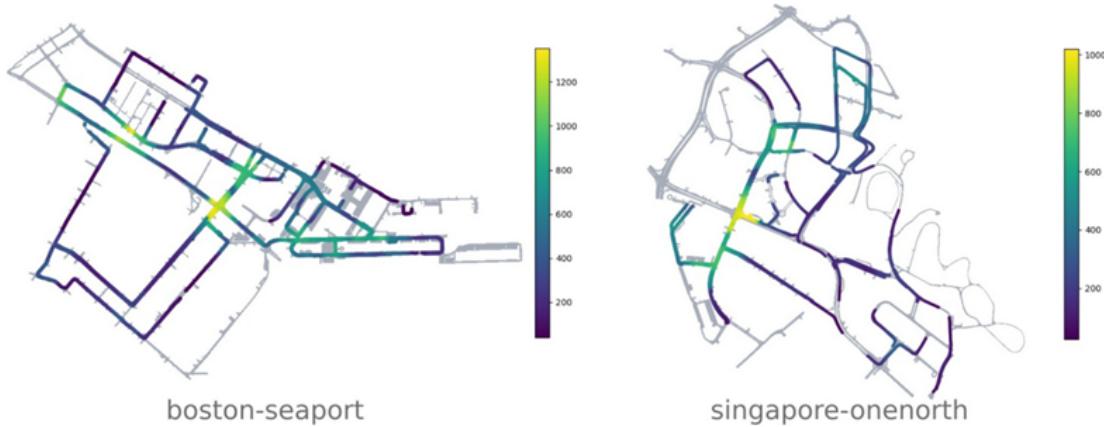


图 2-7 nuScenes 数据集<sup>[48]</sup>

Fig. 2-7 nuScenes datasets<sup>[48]</sup>

## 2.6 本章小结

本章主要对点云语义分割主动域适应相关领域的基础知识做了全面介绍，包含对点云语义分割，主动学习，域适应在内的多个不同领域分别做了介绍。对于点云语义分割相关基础知识，首先详细介绍了点云的获取方式、点云的特征以及室外点云的差异。根据特征提取方式的不同，进一步对点云语义分割任务的基本模型和基本实现方式做了基础介绍，最后还介绍了语义分割任务中常用的评价指标 mIoU。对于主动学习相关基础知识，主要对主动学习方法的基本概念和基本流程做了详细阐述；针对域适应基础知识，首先介绍了域适应的概念、目的以及任务，接着又对常见的域对齐方法进行了梳理和解释。最后还对点云语义分割域适应任务中常用的室外跨域数据集分别进行了介绍。本章介绍的各方面基础知识对后续章节中算法设计的阅读理解起到重要铺垫作用。

## 第3章 基于点云语义分割域适应的主动学习方法

### 3.1 本章引言

本章主要介绍一种新的用于点云语义分割域适应的主动学习方法，该方法提出了一种基于源域原型指导的主动查询策略，并结合 Mixing 方法构建出强壮的中间域数据，极大的提高了点云语义分割域适应模型的性能。接下来，本章节将首先介绍方法的研究动机和贡献，接着对每个子方法模块的原理及实现细节进行详细的介绍，最后本文将通过在主流公开数据集上取得的实验结果以及对消融实验的分析展示方法的有效性。

### 3.2 研究动机及贡献

近年来，三维点云语义分割技术在自动驾驶、智能机器人等领域的应用需求日益迫切。尽管基于深度学习的全监督方法在点云语义分割上取得了显著性能，但其实际部署面临两大核心挑战：标注成本瓶颈与域间分布差异。一方面，点云的逐点标注需耗费大量人力物力，标注单帧车载激光雷达点云需约 2 小时<sup>[47]</sup>。而真实场景中目标域数据因传感器配置、环境动态变化等因素，与源域存在显著分布偏移，导致模型泛化性能急剧下降<sup>[49]</sup>。

为缓解标注压力，现有研究主要沿两条路径展开：主动学习通过选择最具代表性的样本进行标注，以最小标注代价提升模型性能；无监督域适应则尝试在无目标域标注下对齐源域与目标域特征分布。然而，两者在跨域场景中均存在固有局限。传统主动学习方法<sup>[50-52]</sup>的样本选择策略都假定在单模态源域分布上，忽略了潜在的多模态分布，因此选择的样本无法有效指导域间特征对齐，这会导致标注资源浪费并影响模型性能<sup>[53,54]</sup>。无监督虽无需目标域标注，但其依赖于大量的伪标签，而伪标签噪声会随迭代过程累积，限制性能提升，导致其与全监督基线仍存在很大的差异。

针对上述存在的问题，一些学者开始致力于主动域适应方法研究<sup>[55-57]</sup>，其结合主动学习和域适应方法的优势，并在图像语义分割领域取得了一定的成果，然而些方法大多不能直接应用于点云语义分割。一方面，点云数据具有独特的几何结构和稀疏性，与图像数据的网格结构有本质区别；另一方面，点云的数据量庞大且无序，直接迁移图像领域的主动域适应方法无法有效捕捉点云的关键特征。在三维点云中，Annotator<sup>[58]</sup>提出了一种以体素为中心的主动学习方法，用以选择显著且具有代表性的体素，并随后对这些体素内的所有点进行标注。它第一次将主动学习

运用到三维点云语义分割域适应中，并取得了超越其他传统主动学习方法的效果，然而它只考虑了点云特性依然忽略了域间差异。

通过上述分析，本章提出基于点云语义分割域适应的主动学习方法，核心思想是通过源域原型指导目标域上点的选择，并将标注后的目标点与源域点进行混合，组成中间域数据，实现标注效率与域对齐能力的协同优化。构建以下两个模块：1) 域差异感知的主动查询：通过动态构建源域类别原型以代表源域，计算目标域中候选点与源域的偏离程度，筛选同时具备高不确定性与高域差异的目标点。这些样本能够精准暴露域间分布边界，指导模型聚焦于域偏移敏感区域。2) 动态中间域构建：引入 Mixing 方法，随机从源域中采样一定比例的标注点与已标注的目标点云进行混合增强，生成兼具双域信息的中间域数据，该方法增强模型对域不变特征的提取能力，可以进一步缩减域间隙。

本章节研究内容的主要贡献如下：

- 1) 提出了以个面向点云语义分割域适应的主动学习方法，超过传统主动学习方法下的点云语义分割域适应结果，并在极少量的标注下取得了超过最先进方法的结果。
- 2) 提出了一种源域指导的目标点主动选择策略，筛选出兼具高不确定性和高域差异的目标点。
- 3) 首次将主动学习与 Mixing 方法进行结合并运用到域适应领域，动态构建包含双域信息的中间域数据，进一步缩减域间隙。

### 3.3 基于原型指导的主动学习方法

#### 3.3.1 问题陈述

在点云语义分割域适应任务中，给定一个标注的源域数据  $\mathcal{S} = \{(\mathbf{X}_i^s, \mathbf{Y}_i^s)\}_{i=1}^{N^s}$ ，和一个目标域数据  $\mathcal{T} = \{(\mathbf{X}_i^t)\}_{i=1}^{N^t}$ ，其中  $N^t$  和  $N^s$  分别代表目标域和源域点云帧的数量， $\mathbf{X}_i \in \mathbb{R}^{n_i \times 4}$  代表含有  $(x, y, z, i)$  三维坐标点和反射强度的一帧点云集合，并且  $n_i$  代表在第  $i$  帧点云中点的数量。域适应的目标则是在主动学习方法的帮助下，将从标注的源域上训练好的模型  $\mathcal{G}$  迁移泛化到目标域数据上来，并在目标域上实现准确的点云语义分割。

在主动域适应场景中，给定一个未标注的目标域数据集  $\mathcal{T}$ ，需要从中筛选出能够代表目标域且信息量最大的数据子集进行标注。利用新标注的目标域数据，源域训练的分割模型可逐步迭代调整以适应目标域分布，最终实现目标域上的精确语义分割。具体流程如下：首先，基于预训练模型  $\mathcal{G}$  对目标域数据的预测结果，设计查询策略以计算每个未标注目标点的代表性度量得分；随后，选择最具代表性的

目标点子集  $\mathcal{T}_l$  进行标注，并利用其参与分割模型  $\mathcal{G}$  的调优，同时更新未标注目标数据集  $\mathcal{T} = \mathcal{T} - \mathcal{T}_l$ 。该过程循环迭代直至达到预设的主动学习预算  $B$ 。

### 3.3.2 方法概述

本方法的总体框架如图3-1所示。其算法流程主要由三个模块构成：①源域原型构建：通过分割模型从源点云中提取特征，并基于这些特征构建源域原型，并将作为源域的语义表征代表源域。②源域原型指导的数据选择：计算未标记的目标点到原型的特征空间距离，得到原型相似度特征图，并根据最优-次优差异算法生成域差异分数，并将此分数与模型预测的不确定性分数结合，生成最终评分以指导标注候选目标点的选择。③动态混合中间域构建：使用 Mixing 方法，随机从源域中采样一定比例的标注点与已标注的目标点进行混合增强，生成兼具双域信息的中间域数据，并将此数据用于分割模型的微调。

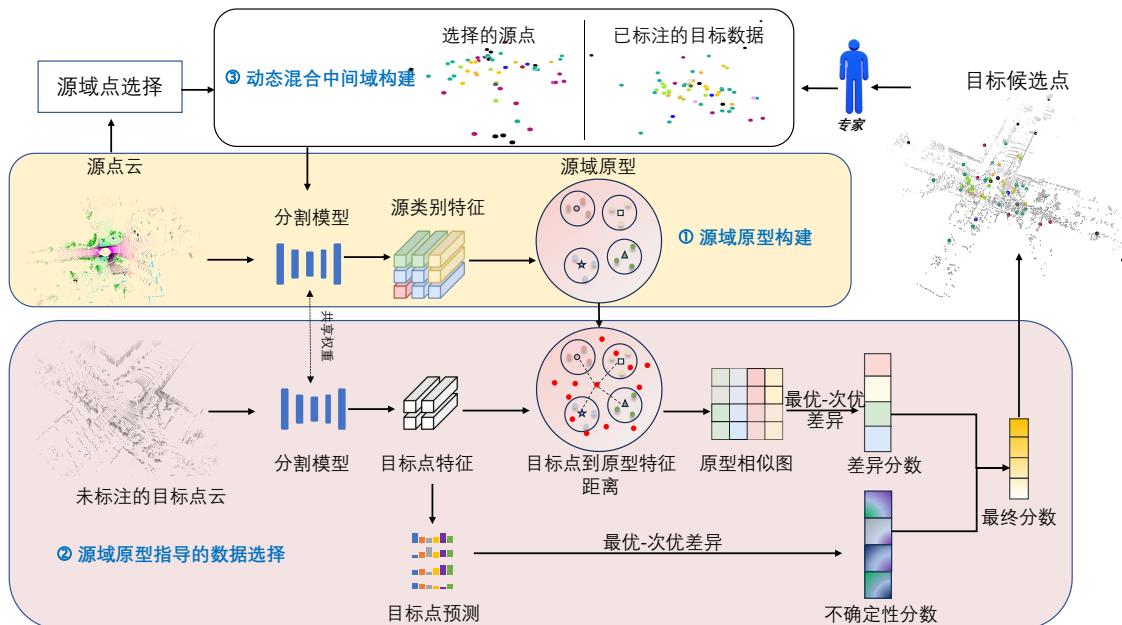


图 3-1 基于点云语义分割域适应的主动学习方法框架

Fig. 3-1 Framework of the active learning method for domain adaptation in point cloud semantic segmentation

### 3.3.3 源域原型构建

为表征源域数据分布的结构特征，首先需要基于特征中心构建源域类别原型。具体而言，对于源域中每个类别的点云样本，利用分割模型  $\mathcal{G}$ ，提取其特征向量，并将同类特征向量的均值作为该类的原型表征。如图3-2所示，将标注的源域数据集  $\mathcal{S}$  输入当前网络  $\mathcal{G}$ ，提取特征矩阵  $\mathbf{F} \in \mathbb{R}^{N_P^S \times d_f}$ ，其中  $N_P^S$  表示源域中所有标注类

别点的数量,  $d_f$  为特征维度, 基于源数据类别信息, 通过公式(3-1)所示计算类别原型  $\mathbf{p}^c$ :

$$\mathbf{p}^c = \frac{\sum_{i=1}^{N_c} \mathbf{f}_i^c}{N_c} \quad (3-1)$$

其中,  $c \in [1, C]$  表示类别索引,  $C$  为源域类别总数;  $\mathbf{f}_i^c$  为类别  $c$  中第  $i$  个点的特征向量;  $N_c$  为类别  $c$  的样本数量, 对应的公式如(3-2)所示:

$$N_c = \sum_{i=1}^{N_P^S} \mathbb{I}(y_i^s = c) \quad (3-2)$$

其中  $y_i^s$  表示第  $i$  个源点特征  $\mathbf{f}_i$  对应的类别标签,  $\mathbb{I}(y_i^s = c)$  为指示函数, 当  $y_i^s$  属于类别  $c$  时取值为 1, 否则为 0。

由于点云数据集庞大, 因此常规服务器设备无法一次性将所有的数据都加载到内存并进计算, 而如果设计全局变量累加多次迭代的结果, 可能会造成一定的精度损失和内存消耗, 为了节省内存资源和保证结果的准确性, 本章采用 Welford 增量均值算法<sup>[59]</sup> 进行渐进式的原型计算, 如公式(3-3)所示:

$$\mathbf{p}_{b+1}^c = \mathbf{p}_b^c + \frac{\mathbf{p}_{b+1}^c - \mathbf{p}_b^c}{x_{b+1}} \quad (3-3)$$

式中,  $\mathbf{p}_{b+1}^c$  代表在第  $b+1$  训练批次时类别  $c$  的原型结果,  $\mathbf{p}_b^c$  代表上一批次时类别  $c$  的原型结果,  $x_{b+1}$  则代表在第  $b+1$  训练批次时类别  $c$  的总数量。通过该算法最终得到源域原型矩阵  $\mathbf{P} \in \mathbb{R}^{C \times d_f} = \{\mathbf{p}^i\}_{i=1}^C$ , 其中每个原型向量  $\mathbf{p}^i$  对应特征空间中源域某类别的质心, 蕴含该类别的语义特征。这些原型将在每一轮的主动学习阶段动态更新, 为跨域数据选择提供指导。

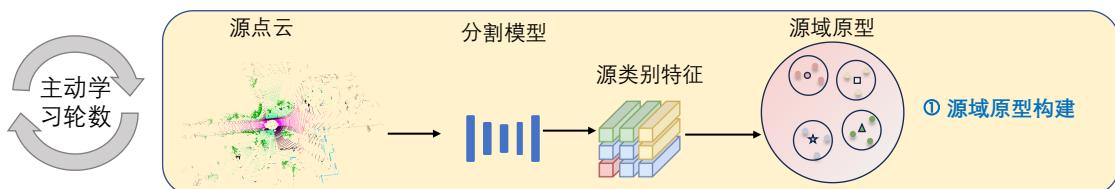


图 3-2 源域原型构建

Fig. 3-2 Source prototype construction

### 3.3.4 源域原型指导的数据选择

源域原型构建完成后, 可将其作为基准指导目标域数据的筛选。如图3-3所示, 将未标注的目标域点云输入预训练分割网络, 提取其特征矩阵  $\mathbf{F}^T \in \mathbb{R}^{N^T \times d_f}$ , 其中  $N^T$  为目标域点数。随后逐点计算其与源域各类别原型的欧氏距离, 其表达式公式

为(3-4):

$$\mathbf{d}_i^c = \|\mathbf{f}_i^t - \mathbf{p}^c\| \quad (3-4)$$

式中  $\mathbf{f}_i^t \in \mathbf{F}^T$  表示目标域第  $i$  个未标注点的特征向量,  $\mathbf{p}^c$  为源域类别  $c$  的原型向量。 $d_i^c$  代表点到源域类别  $c$  的欧式距离, 该距离度量反映了目标点特征与源域类别质心的空间匹配度: 距离越小, 表明目标点特征在源域特征空间中越接近类别  $c$  的聚类中心。

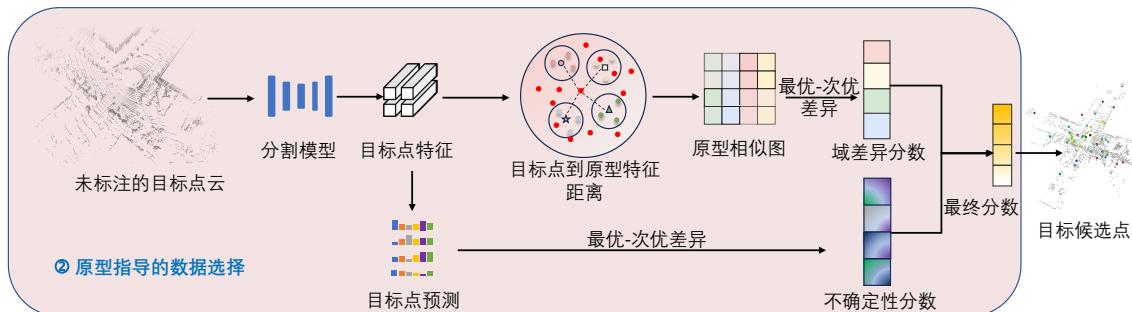


图 3-3 源域原型指导的数据选择

Fig. 3-3 Source-Prototype guided data selection

### 3.3.4.1 计算域差异评分

对每个目标点  $i$  遍历计算与所有类别原型的特征距离, 生成距离向量  $\mathbf{D}_i = [d_i^1, d_i^2, \dots, d_i^C]$ 。为量化其域间分布特性, 需将距离向量转换为相似性度量并进行归一化处理:

1) 相似性转换: 对  $\mathbf{D}_i$  逐元素取倒数, 得到相似性向量  $\mathbf{D}'_i = [1/d_i^1, 1/d_i^2, \dots, 1/d_i^C]$ , 使得距离越近的类别相似度值越高。

2) 概率归一化: 通过 Softmax 函数  $f(\cdot)$  将  $\mathbf{D}'_i$  映射为概率分布, 如公式(3-5)所示, 消除量纲差异增强判别性, 确保不同类别的距离在同一尺度下比较。

$$f(\mathbf{D}'_i) = \text{softmax}(\mathbf{D}'_i) = \left[ \frac{e^{d_i^{1'}}}{\sum_{c=1}^C e^{d_i^{c'}}}, \dots, \frac{e^{d_i^{C'}}}{\sum_{c=1}^C e^{d_i^{c'}}} \right] \quad (3-5)$$

最终通过最优-次优差异算法计算域差异评分  $M_{ds}^i$ , 公式如(3-6)所示:

$$M_{ds}^i = S_{R1}(f(\mathbf{D}'_i)) - S_{R2}(f(\mathbf{D}'_i)) \quad (3-6)$$

其中  $S_{R1}(\cdot)$  和  $S_{R2}(\cdot)$  分别表示最大概率值与次大概率值。 $M_{ds}^i$  越小, 则表明目标点与两个源域类别的相似度接近, 意味着其处于源域类别边界区域, 这样的目标点对缓解域偏移具有更高价值。

### 3.3.4.2 融合不确定性评分

计算得到域差异评分后，为了避免选择的点都是同类别的点，融合不确定性评分进行最终筛选。通过分割头  $h(\cdot)$  获取目标点的预测概率分布  $\mathbf{p}_i^t \in \mathbb{R}^{1 \times C}$ ，并计算其不确定性评分  $M_{us}^i$ ，其表达公式如公式(3-7)所示：

$$M_{us}^i = S_{R1}(\mathbf{p}_i^t) - S_{R2}(\mathbf{p}_i^t) \quad (3-7)$$

该评分反映模型对目标点类别判定的置信度：当最大概率与次大概率差值较小时（即  $M_{us}^i$  较小），表明模型对该点的预测存在较高不确定性，其位于类别边界上无法区分，此类样本的标注可有效提升模型性能。为平衡域差异特性与模型不确定性，采用加权融合策略生成最终评分，其表达式如公式(3-8)所示：

$$M_{final}^i = \alpha \times M_{ds}^i + (1 - \alpha) \times M_{us}^i \quad (3-8)$$

其中， $\alpha \in [0, 1]$  可调节的超参数。当  $\alpha = 0.5$  时，两类评分贡献均等；当目标域与源域分布差异显著时，可增大以强化域差异指导作用，因此在不同的场景下  $\alpha$  可能会有所不同。

### 3.3.4.3 筛选候选样本

基于最终目标评分  $M_{final}^i$ ，对所有目标点进行升序排列，评分越低优先级越高，选取每帧点云中排名前  $k$  的点组成候选样本点集  $\mathcal{T}_l$  提交至专家（Oracle）进行人工标注，同时更新未标注目标数据集  $\mathcal{T} = \mathcal{T} - \mathcal{T}_l$ ，在下一轮的主动学习中，已标注的目标点将不参与筛选，其中  $k$  与主动学习轮数  $R$  以及标注总预算  $B$  的关系如公式(3-9)所示：

$$k = \frac{B}{R \times N^T} \quad (3-9)$$

## 3.3.5 动态混合中间域构建

最后，为了进一步增强模型的泛化能力，本算法引入了 Mixing 混合方法。如图3-4所示，在每一轮训练中任意一帧目标点云都会随机匹配一帧源点云，并随机从源点云中选择一定比例的源点  $\mathbf{S}_{s_i}$ ，将这些选择后的源点与已标注的目标点  $\mathbf{T}_{a_i}$  进行混合，组成含两域信息的中间域数据  $\mathbf{I}_i = concat(\mathbf{T}_{a_i}, \mathbf{S}_{s_i})$ ，其中  $concat(\cdot)$  代表拼接混合。这些中间域数据可以帮助模型学习到域不变特征，进一步缩减域间隙<sup>[60,61]</sup>。

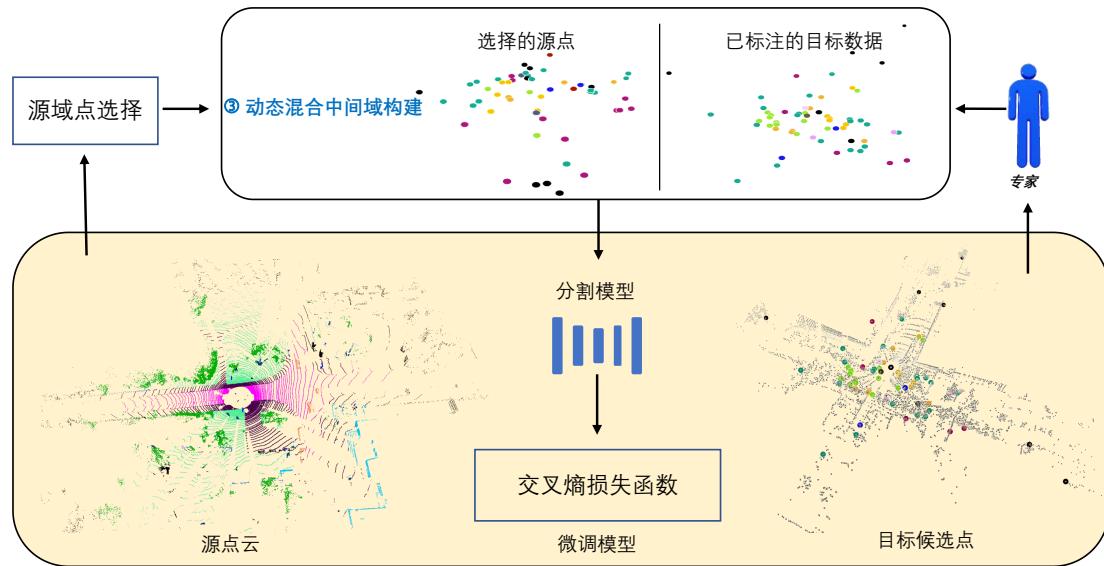


图 3-4 动态混合中间域构建

Fig. 3-4 Dynamic mixed intermediate domain construction

### 3.3.6 实验评估

#### 3.3.6.1 实验设置

在实验中，使用 MinkowskiNet<sup>[42]</sup> 在 Annotator 中的 PyTorch 实现版本作为目标分割网络模型，并使用随机梯度下降 (SGD)<sup>[62]</sup> 作为学习优化器，动量为 0.01，权重衰减系数为 0.0001，在第一轮训练中使用线性预热，将学习率线性增加到基础学习率 0.01，并使用初始学习率为 0.01 的余弦衰减调度器动态调整学习率。所有实验都在单张 NVIDIA RTX A6000 GPU 上进行训练。本章方法在真实到真实以及合成到真实的跨域场景下分别进行了实验。对于所有的场景，主动学习全程总共执行 5 次迭代并达到预设标注预算。在合成到真实的跨域场景实验中，预训练模型 (Source-only) 和全监督模型 (Target-only) 阶段的批量大小设为 16；在 SynLiDAR→SemanticKITTI 实验中训练 10 轮，在 SynLiDAR→SemanticPOSS 实验中训练 20 轮。而在域适应阶段，每一步的批量大小设为 14 并训练 50 轮。权重参数  $\alpha$  分别在 SynLiDAR→SemanticKITTI 和 SynLiDAR→SemanticPOSS 的实验中设置为 0.4 和 0.6。在真实到真实的跨域场景实验中，SemanticKITTI→nuScenes 和 nuScenes→SemanticKITTI 的实验配置相同，预训练模型 Source-only 和全监督模型 Target-only 阶段的每一步批量大小设为 16，并训练 10 轮；在域适应阶段的每一步批量大小设置为 10 并训练 50 轮，权重参数  $\alpha$  为 0.6。

### 3.3.7 实验结果

为了证明本章方法的有效性，分别在合成到真实和真实到真实这两个跨域场景下，对四个数据集进行了实验。随后，通过可视化手段对实验结果进行展示，从而更直观地呈现所提出方法在不同场景中的具体效果。

#### 3.3.7.1 合成到真实场景

在合成到真实跨域场景的实验中，为确保与现有域适应方法的公平比较，选择 SynLiDAR→SemanticKITTI 和 SynLiDAR→SemanticPOSS 这两个主流的合成到真实跨域数据集进行了实验。

表 3-1 本方法与其他域适应方法在 SynLiDAR→SemanticKITTI 数据上的比较

Table 3-1 Comparison with other domain adaptation methods on SynLiDAR→SemanticKITTI

方法	域适应	标注	结果
Source-Only	-	-	22.8
Target-Only	-	100%	60.1
AADA	UDA	-	23.0
AdvEnt	UDA	-	25.8
CRST	UDA	-	26.5
ST-PCt	UDA	-	28.9
PolarMix	UDA	-	32.2
CoSMix	UDA	-	31.0
DGT-ST	UDA	-	43.1
Annotator	ADA	0.1%	57.7
本章方法	ADA	0.1%	<b>58.7</b>

实验 SynLiDAR→SemanticKITTI 的结果如表3-1所示：实验结果表明，在全监督基准测试中，Source-Only 模型与 Target-Only 模型间的性能差达到 37.3 个百分点，直观的反映了合成数据与真实场景间的域间分布差异，表明直接迁移模型到目标域会因为域偏移而导致严重的性能下降。在无监督域适应（UDA）的方法中，各方法性能分布在 22.8% 至 43.1% 区间，其中 DGT-ST 方法以 43.1% 取得最高结果，但相较目标域全监督性能仍存在 17 个百分点的差距。在三维语义分割主动域适应（ADA）方法中，Annotator 是唯一可比较的方法，为保证公平比较，主动学习预算参考其设置为 0.1%，Annotator 与本章 ADA 方法的性能分别达到目标域全

监督基准的 96% 与 97.7%，证明本章方法有效性的同时也表明了主动学习域适应的高效性。提供本数据集下分割可视化如图3-5所示：

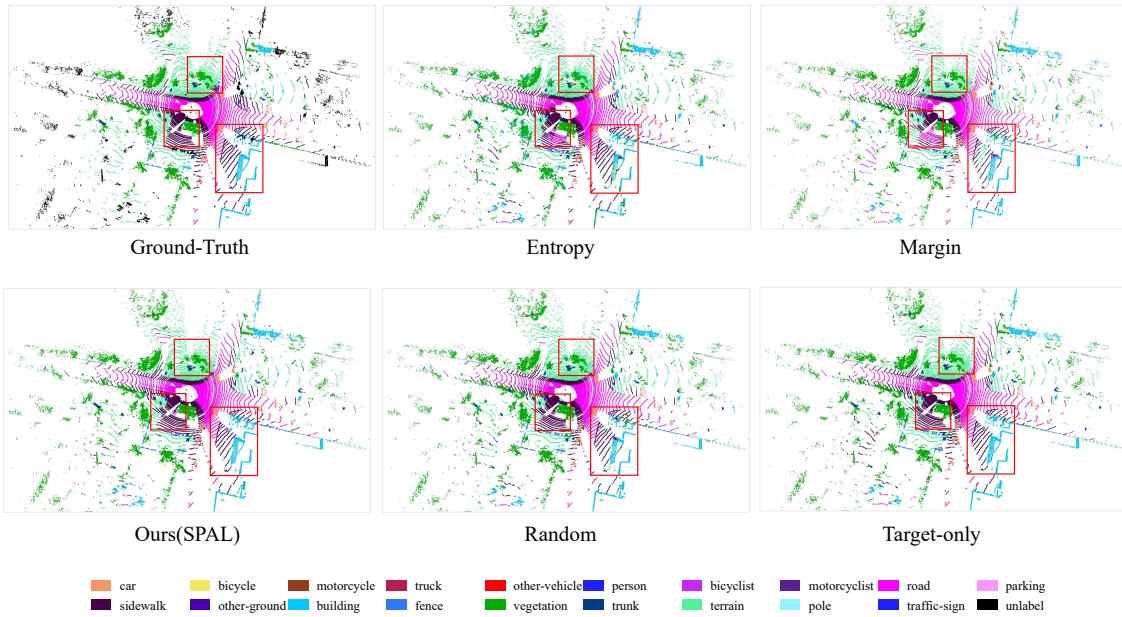


图 3-5 本章 SynLiDAR→SemanticKITTI 分割可视化图

Fig. 3-5 Visualization of the segmentation results in the SynLiDAR→SemanticKITTI

表 3-2 本方法与其他域适应方法在 SynLiDAR→SemanticPOSS 数据上的比较

Table 3-2 Comparison with other domain adaptation methods on SynLiDAR→SemanticPOSS

方法	域适应	标注	结果
Source-Only	-	-	34.6
Target-Only	-	100%	58.0
CRST	UDA	-	27.1
ST-PCT	UDA	-	29.6
PolarMix	UDA	-	30.4
CoSMix	UDA	-	40.4
DGT-ST	UDA	-	50.8
Annotator	ADA	0.1%	52.0
本章方法	ADA	0.1%	<b>56.6</b>

实验 SynLiDAR→SemanticKITTI 的结果如表3-2所示：在无监督域适应（UDA）方法中，DGT-ST 仍以 50.8% 的性能占据首位；而在主动域适应（ADA）方法中，

本章方法在 0.1% 的标注下取得 56.6% 的性能超过 Annotator4.6 个百分点，再一次证明了本章方法在合成到真实的跨域场景的有效性。可视化结果如图3-6所示：

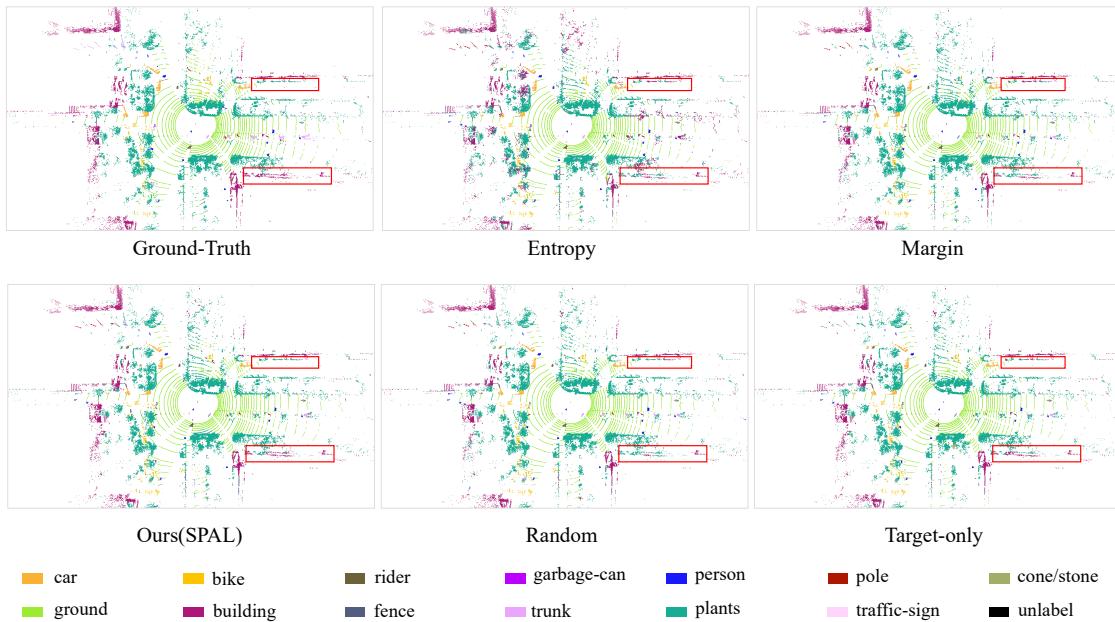


图 3-6 本章 SynLiDAR→SemanticPOSS 分割可视化图

Fig. 3-6 Visualization of the segmentation results in the SynLiDAR→SemanticPOSS

### 3.3.7.2 真实到真实场景

在合成到真实的跨域任务中，合成的数据集一般都有着标注精度更高，噪音度低的特性，其仍然与真实数据集有所差异。为进一步验证方法的泛化能力，本章将方法拓展至“真实到真实”跨域场景，并选择 nuScenes→SemanticKITTI 和 SemanticKITTI→nuScenes 跨域数据集进行了实验，在此场景下，本章方法展现出与合成到真实任务相似的性能优势，进一步证明了本章方法的有效性。

如表3-3所示，在 SemanticKITTI→nuScenes 实验中，目标域全监督基准结果与源域模型间存在 49.0 个百分点的性能差距，这说明在真实数据间，跨域任务要比合成更难。无监督域适应（UDA）方法中，LiDOG 以 34.9% 领先，但其性能仅为目标域基准的 42.2%，说明了无监督域适应在真实场景中的局限性，虽然不用进行标记但其性能仍然离全监督非常远。而本章 ADA 方法以 0.1% 标注量达到目标域全监督的 97.9%，较 Annotator 提升 5.1 个百分点，验证了本方法的有效性。同合成到真实数据集一样，本实验依然提供与 Ground-Truth、Target-Only 以及其他主动学习的可视化对比图，如图3-7所示：

表 3-3 本方法与其他域适应方法在 SemanticKITTI→nuScenes 数据上的比较

Table 3-3 Comparison with other domain adaptation methods on SemanticKITTI→nuScenes

方法	域适应	标注	结果
Source-Only	-	-	33.7
Target-Only	-	100%	82.7
Mix3D	UDA	-	31.5
CoSMix	UDA	-	29.8
SN	UDA	-	25.8
RayCast	UDA	-	30.9
LiDOG	UDA	-	34.9
Annotator	ADA	0.1%	75.9
本章方法	ADA	0.1%	<b>81.0(改)</b>

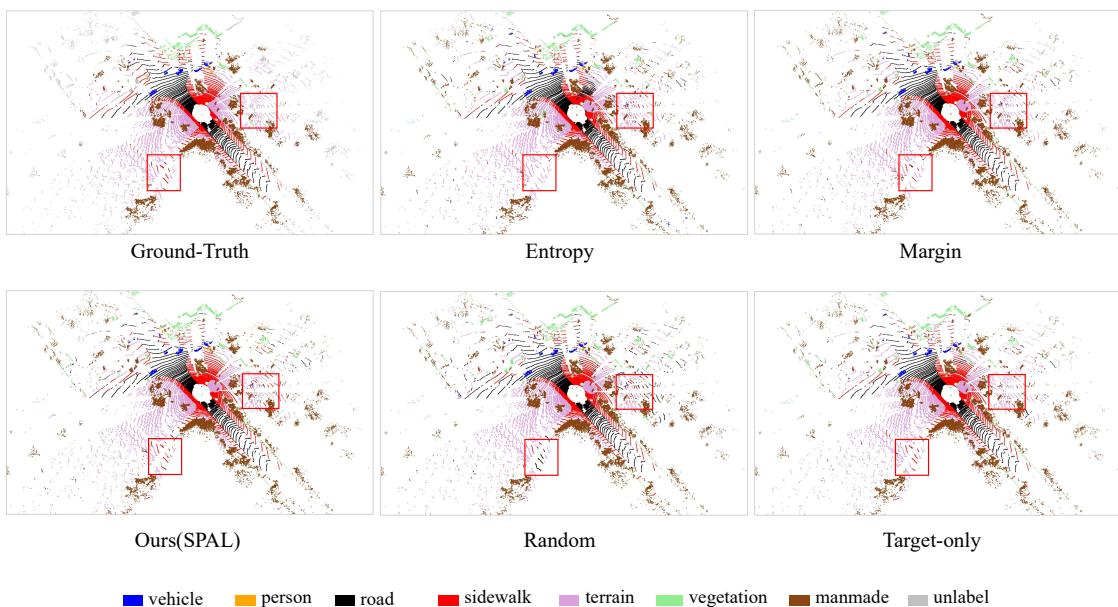


图 3-7 本章 nuScenes→SemanticKITTI 分割可视化图

Fig. 3-7 Visualization of the segmentation results in the SemanticKITTI→nuScenes

在 nuScenes→SemanticKITTI 中如表3-4所示，目标域全监督性能与源域差距进一步扩大至 52.9 个百分点，任务难度进一步增加。值得注意的是，本章 ADA 方法在 0.1% 标注下完全复现目标域全监督性能，较 Annotator 提升 3.6 个百分点，首次实现极低标注量下的无损迁移。对比两类场景，UDA 方法 LiDOG 在 nuScenes→SemanticKITTI 任务中的性能依然强势，但是仍距离全监督有接近 44.2

个百分点的性能差距。综合而言，本章方法在真实到真实场景中均以 0.1% 标注量实现超 95% 全监督性能。可视化结果如图3-8所示：

表 3-4 本方法与其他域适应方法在 nuScenes→SemanticKITTI 数据上的比较

Table 3-4 Comparison with other domain adaptation methods on nuScenes→SemanticKITTI

方法	域适应	标注结果
Target-Only	-	100%
Source-Only	-	-
Mix3D	UDA	-
CoSMix	UDA	-
SN	UDA	-
RayCast	UDA	-
LiDOG	UDA	-
Annotator	ADA	0.1%
本章方法	ADA	0.1% <b>85.4(改)</b>

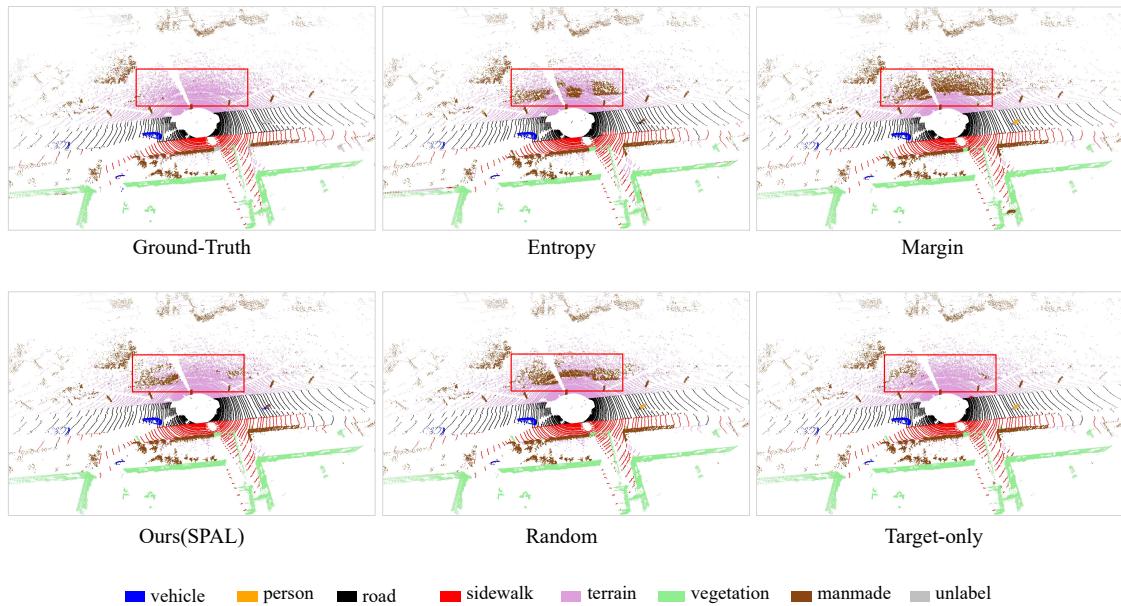


图 3-8 本章 nuScenes→SemanticKITTI 分割可视化图

Fig. 3-8 Visualization of the segmentation results in the nuScenes→SemanticKITTI

### 3.3.8 与其他主动学习方法对比

在未引入 Mixing 策略时，传统主动学习方法在两类合成到真实跨域任务中表现出了一定的优势如表3-5所示。本章的方法是通过源域而构建起的原型，因此比较依赖源域信息，在没有 mixing 的情况下无法发挥最大的效果，在 SynLiDAR→SemanticKITTI 任务中，Margin 方法以 54.4% 的性能取得最优结果，而本章方法（SPAL）以 53.5% 略低 1.1 个百分点，但仍然超过了 Random0.2 个百分点 Entropy2.8 个百分点。而在 SynLiDAR→SemanticPOSS 任务中，本章的主动学习策略（SPAL）低于熵采样（Entropy）0.7 个百分点，却也超过了 Random3.2 个百分点，Margin0.2 个百分点，这一结果表明，传统主动学习策略在特定场景下仍具竞争力，但单一采样准则难以适应跨域任务的复杂性。

表 3-5 本章的主动学习方法与其他传统主动学习方法对比

Table 3-5 Comparison with other active learning methods

数据集	方法	标注	结果
SynLiDAR→SemanticKITTI	Random	0.1%	53.2
	Entropy	0.1%	51.7
	Margin	0.1%	<b>54.4</b>
SynLiDAR→SemanticPOSS	Ours(SPAL)	0.1%	53.5
	Random	0.1%	47.5
	Entropy	0.1%	<b>51.4</b>
	Margin	0.1%	50.5
	Ours(SPAL)	0.1%	50.7

而在结合 Mixing 策略后如表3-6所示，除 Random 以外各主动学习方法在 SynLiDAR→SemanticKITTI 任务中的性能均显著提升，其中本章方法（SPAL）以 58.7% 的性能达到最优，较次优的 Margin 方法提升 1.1 个百分点，较未结合 Mixing 时的自身结果提升 5.2 个百分点且显著超越传统方法 Margin 的 57.6%，Margin、Entropy 则分别较自身提升 3.2 和 3.4 个百分点。这表明结合主动学习和 Mixing 策略的有效性，通过主动筛选出的标注目标点和源点动态构建中间域数据可以有效提升模型的性能，进一步缓解域间分布差异。但 Random 方法下降了 2.1 个百分点，这说明性能增益也与主动学习方法有关系，混合中间域信息包含域差异信息越丰富，其提升程度越高，而本文方法差异选择的是差异性和不确定性最高的点，因此提升幅度最大。

表3-6 本章的主动学习方法与其他传统主动学习方法在结合Mixing后的对比

Table 3-6 Comparison with other active learning methods after integrating Mixing

数据集	方法	标注	结果
SynLiDAR→SemanticKITTI	Random	0.1%	51.1
	Entropy	0.1%	55.1
	Margin	0.1%	57.6
	Ours(SPAL)	0.1%	<b>58.7</b>

### 3.3.9 消融实验

为证明方法的有效性，本章在 SynLiDAR→SemanticKITTI 数据上进行了消融实验，结果如表3-7所示，本章提出的源域指导的主动学习方法（SPAL）与混合增强（Mixing）策略构建的中间域数据对模型性能具有显著协同优化作用。仅使用 SPAL 时，模型性能提升至 50.7%，较基线增加 27.9 个百分点，证明了原型指导的数据选择主动学习方法对目标域关键样本筛选的优势。而当仅使用 Mixing，模型性能为 51.2%，较无任何模块的基线提升 28.3 个百分点，验证了跨域数据融合对缓解域间分布差异的有效性。而当二者联合使用时，模型以 58.7% 的结果达到最优，较单一模块性能分别提升 8.0 和 7.5 个百分点，表明本章方法的真实有效性。

表3-7 本章方法模块消融实验

Table 3-7 Ablation experiments on modules

主动学习 (SPAL)	Mixing	结果
		22.8
✓		50.7
	✓	51.2
✓	✓	<b>58.7</b>

### 3.3.10 本章小结

本章主要研究适用于点云语义分割域适应任务的主动学习方法。为了解决传统主动学习方法中的不足，提出了一种原型指导的主动学习策略，该策略通过动态构建源域原型来代表源域类别质心，并在每一轮主动学习阶段实时更新原型，在进行目标域候选点筛选时，计算每个目标域中未标注的点与每个源域类别原型的相似度，通过最优-次优差异算法获取归一化后的类别概率的差值得到域差异性评

分，值越小说明该点域差异性越高，同时结合不确定性评分得到最终候选评分，升序排列后选取前  $k$  个同时兼备高不确定性和高域差异性的目标点。此外，本章首次将主动学习方法与 Mixing 策略结合，构建包含目标域信息和源域信息的中间域数据，帮助模型学习到更稳定的域不变特征，进一步缩小域间隙。在本章中，首先介绍了方法的主要框架和流程，并分别对方法中的三个模块做了详细介绍，这三个模块共同组成了本章的方法，大幅度提升了模型的跨域性能。同时，为了验证方法的有效性，在两个跨域场景四个数据集上进行了大量实验，并与此前最有效的点云语义分割无监督域适应和主动域适应进行了对比，通过实验分析验证了本章方法的有效性，最后进一步对 Mixing 和 SPAL 模块进行消融实验，充分验证了两个模块的有效性。

## 第4章 基于点云语义分割域适应的主动混合策略

### 4.1 本章引言

本章主要介绍基于点云语义分割域适应的主动混合策略。该方法通过将基于原型指导的主动学习方法和本节所提出的主动混合策略进行深度结合，进一步提升了主动域适应方法的结果。接下来，下文将分别从方法提出的研究动机及主要贡献、方法的具体组成和实现细节，以及实验分析评估等方面，对所提出的方法进行全面阐述。

### 4.2 研究动机及贡献

科技的进步使得获取点云雷达数据变得更加容易，而深度学习技术的发展则推动了点云语义分割任务的迅速提升，涌现出一系列优秀模型并取得了显著成果。然而，这些模型大多基于全监督模式，需要对点云样本进行逐点标注，这是一项耗费大量人力物力的艰巨任务。为缓解这一问题，研究者们提出了多种方法，而域适应就是其中一种有效的策略。在无监督和半监督域适应中，一些方法巧妙地使用混合策略构造中间域，以学习特征不变性，进而解决域偏差问题。*Polarmix*<sup>[63]</sup> 方法通过裁剪并混合不同雷达线束实现源和目标的混合。*CoSMix*<sup>[64]</sup> 方法则交换并混合源域中指定语义类别的点与目标域中伪标签置信度高于阈值的点。此外，主动域适应方法<sup>[56, 65, 66]</sup> 通过主动选择对减小域偏差最有帮助的目标点进行标注，从而提升模型性能。

尽管上述算法各自以不同方式缓解了标注问题，提升了分割模型的性能，但在域适应中，主动学习与混合策略的结合尚未得到深入研究。无论是在图像还是三维点云领域，混合策略和主动学习通常独立应用，分别为减少标注需求做出贡献。然而，现有的混合方法若直接应用于主动域适应，可能存在以下问题：1) 数量不均衡导致的域偏差问题。现有的混合方法多基于同一数据集或大量伪标签，特点是场景连续且点数丰富。然而在域适应中，源域和目标域存在域偏移，主动学习预算下选择的点数量有限。若直接应用这些混合方法，可能导致模型过度学习源域信息，阻碍对目标域信息的提取，最终导致次优结果。因此，在主动域适应中，保持源域和目标域信息的平衡可能比场景连续性更为重要。主动学习选点导致的语义类别不平衡问题。大多数主动学习选点策略基于不确定性。在实际标注前，无法确定所选子集的类别分布是否均衡。尽管一些方法通过伪标签预判类别，但这基于模型不可靠的预测，在域适应任务中可能不适用。此外，现有的混合方法未考虑逐

点的语义类别平衡问题。因此，如何使主动学习选择的目标子集与源数据混合后的训练子集在类别分布上尽可能平衡，仍是一个普遍存在的问题。针对上述问题，本章进一步探讨了主动学习方法与混合策略在域适应任务中的深度结合。在该方法中，首先提出了基于原型指导的主动学习与混合策略相结合的基础框架。在此基础上，提出了面向点云语义分割域适应的源-目标数量平衡算法和类别平衡主动混合算法。源-目标数量平衡算法旨在解决数量不均衡导致的域偏差问题，类别平衡主动混合算法用于解决主动学习选点导致的语义类别不平衡问题。这两个算法有效地实现了主动学习与 Mixing 方法的深度结合，进一步提升了模型的分割性能。

本章研究的主要贡献如下：

- 1) 提出了源-目标数量平衡算法，通过选择与目标域样本中标注数量相同的源点进行混合构建中间域，解决了因数量不平衡导致的域偏差问题，进一步提高了混合中间域的有效性。
- 2) 提出了类别平衡主动混合算法，利用在源-目标数量平衡算法，得到多个候选源点混合子集，计算并选择与标注的目标域混合后类别分布最为均衡的子集进行 mixing，借助源域数据实现主动选点的类别平衡，进一步提升了主动学习的有效性。
- 3) 根据提出的两个算法模块实现了主动学习与 mixing 的深入结合，得到了深度融合主动混合的点云语义分割域适应框架，分割表现领先于所有现存域适应方法。

### 4.3 基于点云语义分割域适应的主动混合策略

在第三章中，我们设计了基于原型的主动学习方法，并初步尝试结合混合方法构建强健的中间域数据，以缩减域偏差，提升模型性能。然而，混合方法与主动学习的结合仍有广阔的探索空间。如何根据域偏差以及主动学习的特点来有效结合混合方法，仍是一个值得深入研究的问题。

为了深入探讨混合（Mixing）方法与主动学习在域适应任务中的深度融合，本章在第三章提出的总体框架基础上进行了改进，改进后的框架如图 x-x 所示。该算法的基本流程主要由四个主要模块构成：①源域原型构建模块；②源原型引导的数据选择模块（SPAL）；③源-目标数量平衡模块（STNB）；④类别平衡主动混合模块（CBAM）。为进一步实现两者的高效协同作用，从而获得更优的分割表现，本章对第三章的动态中间域构建模块进行了改进，分为两个模块：一是源-目标数量平衡模块，选择类别数量大于预设定值的源域帧，并从中筛选与所匹配的目标域帧标注点数平衡的候选子集；二是类别平衡主动混合模块，计算每个候选子集与目标域帧

标注点混合后的类别分布熵值，选择熵值最大的候选源域子集，以构建类别相对平衡的中间域数据。

通过上述改进，旨在实现混合方法与主动学习在域适应任务中的深度融合，进一步提升模型的分割性能。

### 4.3.1 源-目标数量平衡算法

前一章节的实验结果证明了主动学习与 Mixing 方法的结合取得了显著的效果。然而这只是对于两种方法结合的初步探索，对于他们的深度结合仍然有很大的探索空间。在主动域适应中，主动学习标注点的数量极少，又加之域间隙的存在，使得之前的连续场景、或者基于伪标签的 Mixing 方法与主动学习结合并不能发挥其最大的效果。因此，本章的源-目标平衡算法旨在数量层名平衡混合的源域点和标注的目标点，对主动学习与 Mixing 的深入结合进行探索。

在每一轮主动学习迭代中，将最新标注的目标点加入到已标注数据集中，更新数据集  $\mathcal{T}_r^{al}$ ，更新公式如(4-1)所示：

$$\mathcal{T}_r^{al} = \mathcal{T}_{r-1}^{al} \cup \mathcal{T}_r^{al} \quad (4-1)$$

其中， $\mathcal{T}_r^{al}$  是当前主动学第  $r$  轮的主动标注最新数据集，而  $\mathcal{T}_{r-1}^{al}$  是上一轮即第  $r-1$  轮主动标注的数据集，其中  $r$  从 1 开始计算，并且当  $r = 0$  时， $\mathcal{T}_0^{al}$  为空集  $\emptyset$ 。在主动学习阶段结束后，接着就是将已标注的最新的目标域数据与源数据混合。选择一帧带有标注的目标域数据，然后再随机匹配一帧源域数据，为了保证数据的质量，源域数据的筛选是有条件的，即仅当某一帧点云的类别数量大于预设的阈值  $\tau$  时，该帧数据才有资格与当前目标域数据进行混合，筛选过程如(4-2)所示，其中  $\mathbf{S}_i = \{\mathbf{X}_i^S, \mathbf{Y}_i^S\}$ ，表示源域中的一帧点云数据。

$$\mathcal{M}_{mix} = \{\mathbf{S}_i | unique(\mathbf{Y}_i^S) > \tau\}, \quad \mathbf{Y}_i^S \in \mathbf{S}_i \quad (4-2)$$

接着，我们从  $\mathcal{M}_{mix}$  中随机筛选一个源域帧  $\mathbf{M}_i \in \mathcal{M}_{mix}$  与目标域帧  $\mathbf{p}_i$  进行匹配，在匹配成功后，我们将从匹配的源域帧中，候选  $m$  个混合子集，这些候选子集中的点数与匹配的目标域中主动标注的点数量相同，候选点的公式如下所示：

$$\mathbf{Q} = \{\mathbf{q}_1, \dots, \mathbf{q}_m\}, \quad \|\mathbf{q}_i\| = \|\mathbf{p}_i\|, \quad \mathbf{q}_i \subset \mathbf{Q}, \quad \mathbf{p}_i \subset \mathcal{T}_r^{al} \quad (4-3)$$

式中， $\mathbf{Q} \subset \mathbf{M}_i$  为  $m$  个源域候选混合子集的集合， $\mathbf{q}_i$  带表第  $i$  个候选子集， $\mathbf{p}_i$  代表一个目标域点云帧中已标注点的集合。 $\|\mathbf{q}_i\|$  和  $\|\mathbf{p}_i\|$  分别代表候选子集  $\mathbf{q}_i$  和目标点云已标注点  $\mathbf{p}_i$  的数量。

### 4.3.2 类别平衡主动混合算法

针对主动学习在目标域中引发的类别不平衡问题，本章提出类别平衡主动混合算法。在主动学习中，由于所选取点的类别无法提前预知，因此主动选择的点往往会导致目标域每一帧点云中各类别之间所含标注点数存在显著差异。值得关注的是，在跨域点云分割任务中，源域通常具备大量完整标注且可直接利用的语义类别点。而这为本章解决主动学习选择后类别不平衡提供了一个思路，即从源域数据上选择点并与目标域标注点混合，使得混合后的数据中类别分布分相对平衡。混合后的数据中间域数据不仅有助于学习域不变特征，也能有效缓解类别不平衡的问题。

基于源-目标数量平衡模块生成的  $m$  候选子集，平衡模块的核心任务是从集合  $\mathbf{Q}$  中选取最优子集  $\mathbf{q}_{max}$ ，使得该子集与已选数据组合后的整体类别分布达到最优平衡状态。为实现这一目标，本模块采用信息熵作为量化指标，即通过计算候选子集与目标域数据混合后的真实标签分布熵值，筛选能够最大程度缓解类别不平衡的候选子集。具体实施过程定义如下：设动态生成的中间域训练数据集包含  $N_{all}$  个已标注点，其中类别  $c$  的标注点数量为  $N_c$ 。对于候选子集  $\mathbf{q}_i$ ，其与对应目标域标注数据混合后形成的数据子集包含  $N_{mix}$  个点，其中类别的标注点数量为  $N_{mix}^c$ 。为评估候选子集  $\mathbf{q}_i$  的平衡效果，需计算其引入后各类别的相对分布比例。具体方法是将已标注数据总量  $N_{all}$  与候选混合数据量  $N_{mix}$  进行叠加，按公式(4-4)逐类计算混合后的分布比例  $\{R_{i,c}\}_{c=1}^C$ 。

$$R_{i,c} = \frac{N_c + N_{mix}^c}{N_{all} + N_{mix}} \quad (4-4)$$

同时，为了保证在同一个量纲下比较，对  $R_{i,c}$  使用 softmax 函数进行归一化处理，得到  $\hat{R}_{i,c}$ ，如公式(4-5)所示：

$$\hat{R}_{i,c} = \frac{e^{R_{i,c}}}{\sum_{c=1}^C e^{R_{i,c}}} \quad (4-5)$$

其表示选择候选子集  $\mathbf{q}_i$  与当前已标注的目标点云帧混合后，各类别所占点数的归一化概率。再然后，通过计算分布的熵值来可作为候选子集的选择评判指标，如公式(4-6)所示：

$$H_i(\hat{R}_i) = - \sum_{c=1}^C \hat{R}_{i,c} \log(\hat{R}_{i,c}) \quad (4-6)$$

其中， $H_i$  表示选择候选子集  $\mathbf{q}_i$  混合后类别分布的熵值结果，并选择熵值最大的一个候选子集  $\mathbf{q}_{max} = \{\mathbf{X}_{\mathbf{q}_{max}}, \mathbf{Y}_{\mathbf{q}_{max}}\}$  作为最终混合源域集，与目标域标注点集

$\mathbf{p}_i = \{\mathbf{X}_{p_i}, \mathbf{Y}_{p_i}\}$  组成新的中间域数据集  $\mathbf{I} = \{\hat{\mathbf{X}}, \hat{\mathbf{Y}}\}$ , 如公式(4-7)所示:

$$\begin{aligned}\hat{\mathbf{X}} &= concat\{\mathbf{X}_{q_{max}}, \mathbf{X}_{p_i}\} \\ \hat{\mathbf{Y}} &= concat\{\mathbf{Y}_{q_{max}}, \mathbf{Y}_{p_i}\}\end{aligned}\quad (4-7)$$

其中,  $\hat{\mathbf{X}}$  表示混合的点数据,  $\hat{\mathbf{Y}}$  则表示对应的标签。最后更新训练集总点数以及类别点数, 公式如(4-8)所示:

$$N_c = N_c + N_{mix}^c, \quad N_{all} = N_{all} + N_{mix} \quad (4-8)$$

### 4.3.3 损失函数

在后续的模型训练中, 仅采用混合后的中间域数据进行微调优化。由于这些数据均包含标注信息, 本章采用交叉熵损失函数作为优化策略, 如公式(4-9)所示, 其中  $\hat{x}_i \in \hat{\mathbf{X}}$ ,  $\hat{y}_i \in \hat{\mathbf{Y}}$ :

$$\mathcal{L}_{CE} = -\frac{1}{|I|} \sum_{i \in I} \sum_{c=1}^C \hat{y}_i^c \log h(\hat{x}_i^c) \quad (4-9)$$

## 4.4 实验评估

### 4.4.1 实验设置

在本章实验中, 同样使用 MinkowskiNet<sup>[42]</sup> 在 Annotator 中的 PyTorch 实现版本作为目标分割网络模型, 并使用随机梯度下降 (SGD)<sup>[62]</sup> 作为学习优化器。所有实验都在单张 NVIDIA RTX A6000 GPU 上进行训练。本章方法同样在真实到真实以及合成到真实的跨域场景下分别进行了实验。对于所有的场景, 主动学习全程总共执行 5 次迭代并达到预设标注预算。由于在四个跨域数据集上的映射类别数量不同, 参数  $\tau$  在 SynLiDAR→SemanticKITTI、SynLiDAR→SemanticPOSS、SemanticKITTI→nuScenes 和 nuScenes→SemanticKITTI 分别设置为 13、9、6、6。此外, 对于其他实验参数的配置仍延续第三章的实验设定。

### 4.4.2 实验结果

本章方法同样在合成到真实场景下的跨域数据集 SynLiDAR→SemanticKITTI 和 SynLiDAR→SemanticPOSS, 以及真实到真实场景下的跨域数据集 SemanticKITTI →nuScenes 和 nuScenes→SemanticKITTI 上做了相应的实验, 并与最先进的方法以及前一章的方法进行了对比以验证其有效性。为了公平比较, 如果没有特殊标明标注预算的情况下, 默认都是在 0.1% 标注预算下做出的实验结果。

#### 4.4.2.1 合成到真实场景

表 4-1 本方法与其他域适应方法在 SynLiDAR→SemanticKITTI 数据上的比较  
Table 4-1 Comparison with other domain adaptation methods on SynLiDAR→SemanticKITTI

方法	域适应	标注	结果
Source-Only	-	-	22.8
Target-Only	-	100%	60.1
AADA	UDA	-	23.0
AdvEnt	UDA	-	25.8
CRST	UDA	-	26.5
ST-PCT	UDA	-	28.9
PolarMix	UDA	-	32.2
CoSMix	UDA	-	31.0
DGT-ST	UDA	-	43.1
MME	SSDA	0.04%	24.5
APE	SSDA	0.04%	25.1
APE-PCT	SSDA	0.04%	27.0
CoSMix-SSDA	SSDA	0.04%	34.3
本章方法	SSDA	0.04%	50.5
Annotator	ADA	0.1%	57.7
前章方法	ADA	0.1%	58.7
本章方法	ADA	0.1%	<b>65.5</b>

本章在 SynLiDAR→SemanticKITTI 跨域数据集上的实验如表4-1所示，分析对比不同的结果可知，在没有任何域适应的情况下，Source-Only 模型在目标域上的性能非常低，仅有 22.8%，这说明直接将源域训练的模型用到目标域效果很差。而使用全部目标域数据训练的模型（Target-Only）达到了 60.1% 的结果，这说明域间隙的存在会导致在源域训练好的模型在目标域上性能急剧下降。

在不需要目标域标注的无监督域适应（UDA）方法中，DGT-ST 的效果最好，达到 43.1%，比 Source-Only 提升了近 20 个百分点，但相比 Target-Only 仍有较大差距。这说明即使不标注目标域数据，通过域适应也能部分缩小域间差异，但还不能完全解决问题。为了与半监督域适应方法进行公平比较，本章将主动学习的标注预算降低到与半监督同一量级即 0.04%，即使在这种极少量的标注下，本章方法仍

达到了 50.5% 的结果，比同样标注量的 CoSMix-SSDA 高出了近 16 个百分点。这说明在标注极少的情况下，本章方法能更有效地利用有限的标注信息。

在与主动域适应方法进行比较时，标注比例提升到 0.1%，本章方法的结果达到了 65.5%，不仅比前章方法提高了近 7 个百分点，甚至超越了 Target-Only，这说明本章方法构建的中间域增强了模型的性能，学习到了源和目标域的信息，因此超越了全监督结果。当然，超越 Target-Only 本算法并非先驱，在之前的一些域适应文章中<sup>[67]</sup> 也有做到。另外，值得注意的是，虽然标注量增加了 2.5 倍，但性能提升幅度远高于标注量的增长比例，这说明在前一章的基础上，结合本章主动混合策略，充分发挥了它们的最佳性能。

表 4-2 本方法与其他域适应方法在 SynLiDAR→SemanticPOSS 数据上的比较

Table 4-2 Comparison with other domain adaptation methods on SynLiDAR→SemanticPOSS

方法	域适应	标注	结果
Source-Only	-	-	34.6
Target-Only	-	100%	58.0
CRST <sup>[2]</sup>	UDA	-	27.1
ST-PCT	UDA	-	29.6
PolarMix	UDA	-	30.4
CoSMix	UDA	-	40.4
DGT-ST	UDA	-	50.8
MME	SSDA	0.01%	33.2
APE	SSDA	0.01%	30.3
APE-PCT	SSDA	0.01%	31.2
CoSMix-SSDA	SSDA	0.01%	41.0
本章方法	SSDA	0.01%	57.5
Annotator <sup>[58]</sup>	ADA	0.1%	52.0
前章方法	SSDA	0.1%	56.6
本章方法	ADA	0.1%	<b>60.2</b>

如表4-2结果显示，在 SynLiDAR→SemanticPOSS 数据集上域差异依然显著。在无监督域适应（UDA）中，DGT-ST 以 50.8% 的表现达到最优，但距离全标注仍有 7 个百分点的差距。本章方法在 0.01% 的极低标注预算下达到了 57.5% 的结果，远超 CoSMix-SSDA，甚至接近 Target-Only 水平。当与主动域适应方法（ADA）进行比较时，标注量提升至 0.1%，本章方法以 60.2% 的结果超越前章方法和 Annotator

分别 3.6 和 7.8 个百分点，超过 Targe-Only 2.2 个百分点，这证明本章的主动混合策略是有效果的，在结合第三章的方法后可以大幅度提升模型性能。

#### 4.4.2.2 真实到真实场景

SemanticKITTI→nuScenes 的结果如表4-3所示，Source-Only 模型在目标域的结果仅为 33.7%，而全标注的 Target-Only 模型则达到了 82.7%，这验证了真实到真实域场景中源域与目标域的巨大差异。在无监督域适应（UDA）方法中，LiDOG 以 34.9% 的表现最优，但仍远低于全标注结果，表明纯无监督策略在复杂域差异下的局限性。在主动域适应（ADA）场景下，本章方法以 81.0% 的结果显著超越 Annotator 的 75.9%，提升幅度达 5.1 分，且与 Target-Only 的差距缩小至 1.7 个百分点。**尽管前章方法的具体数值缺失**，但从结果趋势可推断本章方法通过动态混合策略有效利用有限标注信息，在极低标注成本下逼近全标注性能，证明了其在真实跨域场景中的有效性。

表 4-3 本章方法与其他域适应方法在 SemanticKITTI→nuScenes 数据上的比较

Table 4-3 Comparison with other domain adaptation methods on SemanticKITTI→nuScenes

方法	域适应	标注	结果
Source-Only	-	-	33.7
Target-Only	-	100%	82.7
Mix3D	UDA	-	31.5
CoSMix	UDA	-	29.8
SN	UDA	-	25.8
RayCast	UDA	-	30.9
LiDOG	UDA	-	34.9
前章方法	ADA	0.1%	?
Annotator	ADA	0.1%	75.9
本章方法	ADA	0.1%	<b>81.0</b>

如表4-4数据显示，在 nuScenes→SemanticKITTI 的实验结果中，Source-Only 模型仅得 32.5%，而 Target-Only 模型通过全标注数据达到 85.4%，再次印证域差异的显著影响。在无监督域适应（UDA）方法中，LiDOG 以 41.2% 的表现依然取得最优，但仍与全标注结果相差 44.2 个百分点。在标注量仅 0.1% 的主动域适应（ADA）场景下，本章方法以 86.2% 的结果超越 Target-Only 0.8 个百分点，远超 Annotator 的 81.8%。**尽管前章方法的具体数值缺失**，但本章方法的突破性结果表明，通过动态

混合策略在极低标注量下超越了全标注相当的性能，进一步证明了本章方法的真实有效性。

表 4-4 本方法与其他域适应方法在 nuScenes→SemanticKITTI 数据上的比较

Table 4-4 Comparison with other domain adaptation methods on nuScenes→SemanticKITTI

方法	域适应	标注结果	
Target-Only	-	100%	85.4
Source-Only	-	-	32.5
Mix3D <sup>[68]</sup>	UDA	-	32.4
CoSMix	UDA	-	36.8
SN	UDA	-	23.6
RayCast	UDA	-	31.5
LiDOG	UDA	-	41.2
前章方法	ADA	0.1%	?
Annotator	ADA	0.1%	81.8
本章方法	ADA	0.1%	<b>86.2</b>

#### 4.4.3 消融对比实验

表 4-5 本章方法与其他 Mixing 方法对比

Table 4-5 Comparison with other mixing methods

主动学习	Mixing 方法	标注	结果
SPAL	LaserMix	0.1%	39.6
	PolarMix	0.1%	?
	Ours	0.1%	<b>65.5</b>

表4-5的对比实验在 SPAL 框架下统一采用 0.1% 标注量进行公平比较。在相同标注条件下，传统 LaserMix 方法仅取得 39.6% 的评估结果，而本章提出的动态混合方法以 65.5% 的显著优势超越前者，性能提升幅度达 25.9%。这一结果验证了传统混合方法在跨域数据融合时对类别分布不敏感，数量过多导致模型学习的知识更偏向源域的问题，而本章方法通过源-目标的数量平衡算法以及熵驱动的源域筛选机制与动态平衡算法，能够精准选择与目标域互补的源域样本，有效缓解混合过程中的类别不均衡问题。此外，尽管 PolarMix 的具体数值缺失，但其基于固定几

何变换的混合策略通常难以适应复杂域差异场景，本章方法在相同标注约束下的突破性表现，进一步证明了动态混合机制在跨域主动学习中的核心价值。

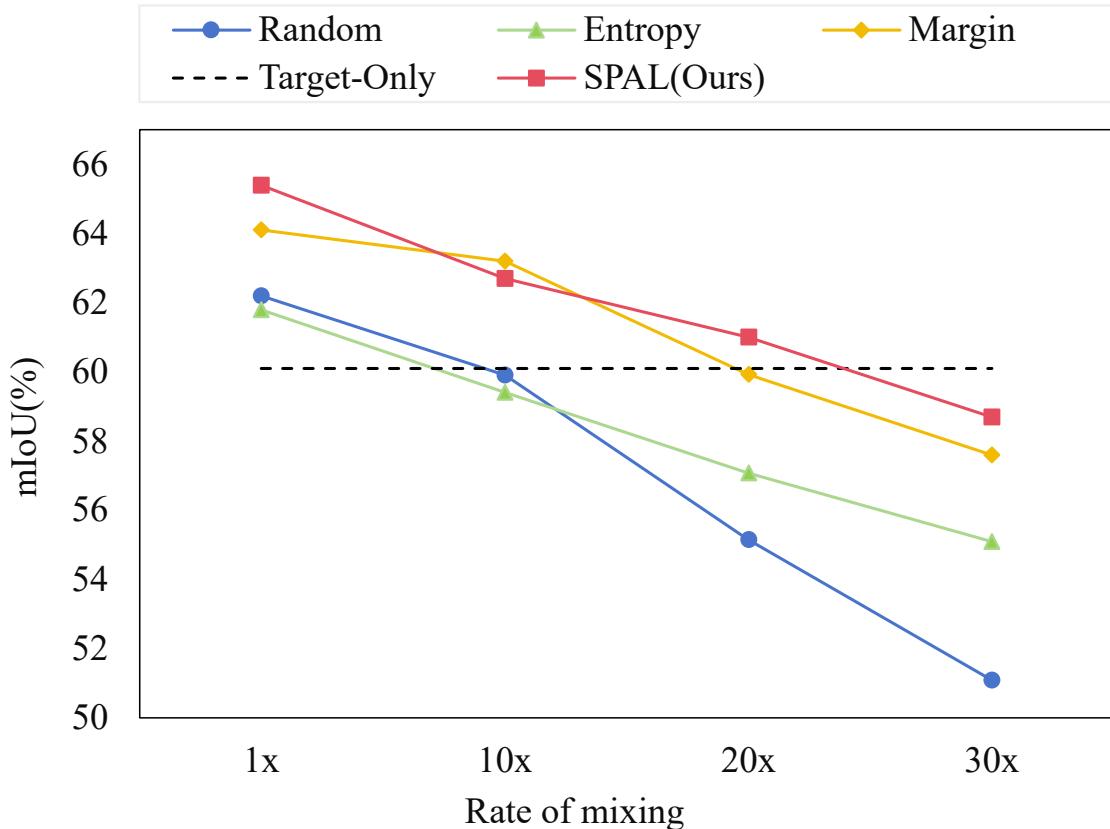


图 4-1 本章不同主动学习在多个混合比例下的对比结果

Fig. 4-1 Comparison results of different active learning methods under various mixing ratios

如图4-1所示，本章在 SynLiDAR→SemanticKITTI 数据集上进行了对比实验，展示了不同主动学习策略在不同源-目标混合比例下的性能对比。实验结果显示，在默认 0.1% 的标注预算下，本章提出的源-目标域数量平衡算法（即源域与目标域数据按 1:1 比例动态混合）在多种主动学习方法中均取得了最优的结果，这证明了算法的有效性，根据域适应以及主动学习的特点，简单高效的提升了性能。而在源-目标域数量平衡算法下，前一章提出的 SPAL 方法的结果又是最高的，达到了 65.5% 的结果，这证明了 SPAL 与本章方法结合的有效性。

为证明本章方法结合前章 SPAL 方法的有效性，在四个跨域数据集（SynLiDAR→SemanticKITTI、SynLiDAR→SemanticPOSS、SemanticKITTI→nuScenes、nuScenes→SemanticKITTI）上均进行了实验。如表4-6所示，在四个跨域数据实验中，结合两章的算法均取得最高结果，且稳定超越其他主动学习方法。这验证了第四章提出的动态混合策略与第三章 SPAL 框架结合的有效性和普适性。这一跨数据集的全面优势表明，源-目标平衡机制能够适配不同域差异场景，显著提升模型的性能。

表4-6 本章算法结合不同主动学习方法结果对比

Table 4-6 Comparison with different active learning methods that incorporate this chapter's modules

数据集	方法	标注	结果
SynLiDAR→SemanticKITTI	Random	0.1%	62.2
	Entropy	0.1%	61.8
	Margin	0.1%	64.0
	Ours(SPAL)	0.1%	<b>65.5</b>
SynLiDAR→SemanticPOSS	Random	0.1%	58.3
	Entropy	0.1%	55.6
	Margin	0.1%	60.0
	Ours(SPAL)	0.1%	<b>60.2</b>
SemanticKITTI→nuScenes	Random	0.1%	85.7
	Entropy	0.1%	83.2
	Margin	0.1%	85.9
	Ours(SPAL)	0.1%	<b>86.2</b>
nuScenes→SemanticKITTI	Random	0.1%	77.7
	Entropy	0.1%	76.5
	Margin	0.1%	80.7
	Ours(SPAL)	0.1%	<b>81.0</b>

表4-7 本章方法模块消融实验

Table 4-7 Ablation experiments on modules

SPAL	STNB	CBAM	结果
			22.84
✓			58.70
✓	✓		65.46
✓	✓	✓	<b>65.51</b>

最后，在SynLiDAR→SemanticKITTI跨域数据上进行了本章的消融实验，主动学习默认使用0.1%的标注预算。如表4-7所示，结果证明本章提出的两个模块对性能提升均有贡献。当任何模块都不用时，基线结果仅为22.84%。当仅使用第三章的SPAL模块时，性能提升至58.70%。在引入源-目标平衡模块(STNB)后，性能

跃升至 65.46%，表明在域差异场景下，数量平衡的混合能帮助模型学习到更有效的域不变特征，显著缓解域差异问题。最终完整方法以 65.51% 达到最优，CBAM 进一步优化了 0.05 个百分点，说明其在解决类别平衡问题以及性能提升上也有所贡献。

## 4.5 本章小结

本章提出了一种面向点云语义分割域适应的深度融合主动学习与混合策略，重点探索两者协同作用对域适应性能的提升。通过设计源-目标数量平衡算法（STNB），在每轮主动学习中动态匹配源域与目标域标注点的数量，确保混合数据中双域信息均衡融合。同时，类别平衡主动混合算法（CBAM）利用类别分布熵值计算从多个候选源域子集中选择混合后分布最均衡的集合，增强主动学习与混合策略的协同效率。在两个跨域场景下的四个跨域数据集上的实验表明，在 0.1% 标注量下，本章完整方法在四个跨域数据集中均达最优的性能，并且显著超越了传统混合方法，最后的消融实验显示模块协同作用时性能提升最大，充分验证了本章算法的有效性。

## 第5章 总结与展望

### 5.1 主要结论

随着科技的发展，计算机三维视觉与生产生活联系的越来越紧密，对点云的自动化处理成为了一个急切的需求。在自动驾驶的城市建图，在机器人领域的姿态估计以及虚拟现实中的三维建模，点云配准的应用广泛分布于各个生产生活环节。如何快速高效的实现各种复杂真实场景的点云配准是一项具有挑战和意义的研究。针对点云配准任务，本文提出了一种基于显著锚点的点云配准框架，它通过第三章的几何嵌入增加弱几何区域的特征差异性，通过引入第四章的多模态融合模块增加锚点的显著性。其中第四章可以看成是

针对第三章方法锚点选择的局限性做的进一步改进。两个方法都在真实场景的点云配准数据集上进行了实验和评估，实验结果表明本文提出的方法能够有效地在低重叠率得场景中，增强特征间的差异性提高相似区域重复模式的匹配成功率，并实现了当前点云配准方法的先进水平。两个方法得贡献如下：

(1) 在基于显著锚点的点云配准方法中，通过提取显著锚点利用锚点与超点、超点与超点间的距离和角度等几何结构信息进行特征嵌入，增加了相似不重叠区域的差异性，能够有效提高超点匹配的内点率。该方法使用 KPConv 网络来提取点云局部区域的超点特征。利用一个锚点定位模块选取若干保持一定几何结构的高置信度的锚点，并通过注意力机制对点云中的超点进行结构嵌入并寻找超点间的对应关系。最后，在经过将超点对应扩充为点对应之后，利用一个局部到全局的姿态估计得到最终的变换矩阵。

(2) 在基于多模态特征融合的锚点定位点云配准方法中，通过融合点云和图像两种模态的信息，提高锚点选择的可靠性。该方法首先利用对其模块，将不同模态的两种数据进行对齐，寻找到点云到像素的对应关系。在多模态融合模块，将两种模态的特征分解为模态相关和模态无关的特征，并在模态无关子空间中缩小特征间的域间隙减少噪声干扰。并最终与模态相关的特征融合以减少信息的丢失形成最终的特征，实现锚点定位。

### 5.2 研究展望

本文提出了基于显著锚点几何嵌入的点云配准和基于多模态融合的锚点定位点云配准方法，虽然两个方法都在低重叠率的真实场景数据集上取得了不错的效果，但是仍然存在一些可以改进的地方。本文的第三章提出了一种基于显著锚点

几何嵌入的点云配准方法，其核心思想是通过多个保持一定几何机构的锚点缓解相似不重叠区域特征过度平滑问题。虽然该方法取得了一定的效果，但是仍然存在一些尚需改进的地方：(1) 首先该方法虽然设计了一个锚点定位模块并利用迭代优化更新显著锚点，但是这种设计产生的锚点在某些场景中依然会失败，并导致最终的结果相较于一般方法较差。为此，需要设计一个更加鲁棒的锚点定位模块使得整体网络更加稳定，可以考虑设计一个损失函数来有效监督锚点对应。(2) 其次在使用由粗到细的点云配准框架之后，整个网络的模型较大导致训练时间较长，如何有效轻量化模型是一个急需解决的问题。后续可以通过提高下采样倍率减少超点个数，进而减少几何嵌入过程的时间开销。

本文的第四章提出以一种基于多模态融合的锚点定位点云配准方法，其核心思想是通过将图像信息和点云信息进行特征融合提高锚点对应的准确性。该方案针对第三章框架做出一点改进并取得了一定效果，但也存在一些问题：(1) 点云数据集中每个点云实际是由 50 张 RGB-D 图像合成，而文章中仅采取某一视角下的一张图片进行融合导致某些点在该视角下被遮挡找不到准确的图像信息，但是如果使用全部图像又会导致时间花销较大，故需要有效实验对图像数量对模态融合的影响进行分析。(2) 在多模态融合模块中，将两种模态的特征投影到模态相关和模态无关的两个子空间并分别学习模态相关与无关的特征表示，后续工作可以重新设计更加适应点云和图像融合的损失函数对其进行监督以达到预设效果。同时在最终的融合过程中使用多头注意力机制完成，后续工作可以考虑使用其他的多模态融合方法。

如何增加点特征间的差异性缓解特征的过渡平滑是点云配准任务的关键，提出的两个方法都是借助锚点嵌入几何信息来提取最终特征。但是由于点云点的个数较多，在做特征提取时导致时间和空间花销较大，影响了整个模型的训练效率。在后续工作中，可以考虑使用与训练好的特征提取网络来提前提取好特征，训练时则读取相应的特征，以减少训练过程中的时间花销是整个网路的参数量大大减少。同时随着点云和图像多模态融合的研究越发深入，对于这两种模态如何更好地融合有了更多的考量。相比于直接利用图像特征修饰点云，使用特征间的融合更加有效；相比于特征间的隐式融合，通过对齐两种模态的显式特征融合更加优越，后续工作可以对点云和图像特征的融合方式开展广泛的实验研究。同时为了能够将现有网络模型部署到例如火星探测等相关实验平台，设计轻量化的网络结构也是一种新的研究方向。

## 参考文献

- [1] UY M A, LEE G H. PointNetVLAD: Deep point cloud based retrieval for large-scale place recognition[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA, 2018 : 4470–4479.
- [2] 赵夫群, 周明全. 文物点云模型的优化配准算法 [J]. 计算机应用研究, 2017, 34(12) : 4.
- [3] 宋丽梅. 双目立体机器视觉检测系统及其应用 [J]. 西南科技大学学报, 2006, 21(1) : 30–34.
- [4] SOBREIRA H, COSTA C M, SOUSA I, et al. Map-matching algorithms for robot self-localization: a comparison between perfect match, iterative closest point and normal distributions transform[J]. Intelligent & Robotic Systems, 2019, 93 : 533 – 546.
- [5] CATTANEO D, VAGHI M, VALADA A. LCDNet: Deep loop closure detection and point cloud registration for LiDAR SLAM[J]. IEEE Transactions on Robotics, 2022, 38(4) : 2074 – 2093.
- [6] LIU Z, ZHOU S, SUO C, et al. LPD-Net: 3D point cloud learning for large-scale place recognition and environment analysis[C]. IEEE/CVF International Conference on Computer Vision, Seoul, Korea, 2019 : 2831 – 2840.
- [7] POMERLEAU F, COLAS F, SIEGWART R, et al. A review of point cloud registration algorithms for mobile robotics[J]. Foundations and Trends® in Robotics, 2015, 4(1) : 1 – 104.
- [8] BESL P, MCKAY N D. A method for registration of 3-D shapes[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1992, 14(2) : 239 – 256.
- [9] GOLD S, RANGARAJAN A, LU C-P, et al. New algorithms for 2D and 3D point matching: pose estimation and correspondence[J]. Pattern Recognition, 1998, 31(8) : 1019 – 1031.

- [10] YANG J, LI H, JIA Y. Go-ICP: Solving 3D registration efficiently and globally optimally[C]. IEEE/CVF International Conference on Computer Vision, Sydney, Australia, 2013 : 1457–1464.
- [11] ALMOHAMAD H, DUFFUAA S O. A linear programming approach for the weighted graph matching problem[J]. IEEE Transactions on pattern analysis and machine intelligence, 1993, 15(5) : 522–525.
- [12] HUANG X, ZHANG J, FAN L, et al. A systematic approach for cross-source point cloud registration by preserving macro and micro structures[J]. IEEE Transactions on Image Processing, 2017, 26(7) : 3261–3276.
- [13] ZHOU F, De la TORRE F. Factorized graph matching[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Providence, USA, 2012 : 127–134.
- [14] LEORDEANU M, HEBERT M. A spectral technique for correspondence problems using pairwise constraints[C]. IEEE/CVF International Conference on Computer Vision, Beijing, China, 2005 : 1482–1489.
- [15] EVANGELIDIS G D, KOUNADES-BASTIAN D, HORAUD R, et al. A generative model for the joint registration of multiple point sets[C]. European Conference on Computer Vision, Zurich, Switzerland, 2014.
- [16] MYRONENKO A, SONG X. Point set registration: coherent point drift[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 32(12) : 2262–2275.
- [17] FAN J, YANG J, AI D, et al. Convex hull indexed Gaussian mixture model for 3D point set registration[J]. Pattern Recognition, 2016, 59 : 126–141.
- [18] AOKI Y, GOFORTH H, SRIVATSAN R A, et al. PointNetLK: robust & efficient point cloud registration ssing pointNet[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seoul, Korea, 2019 : 7156–7165.
- [19] BAKER S, MATTHEWS I. Lucas-Kanade 20 years on: A unifying framework[J]. International Journal of Computer Vision, 2004, 56 : 221–255.
- [20] DENG H, BIRDAL T, ILIC S. PPFNet: Global context aware local features for robust 3D point matching[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA, 2018 : 195–205.

- [21] HUANG X, MEI G, ZHANG J. Feature-Metric registration: A fast semi-Supervised approach for robust point cloud registration without correspondences[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle, USA, 2020 : 11363 – 11371.
- [22] XU H, LIU S, WANG G, et al. OMNet: Learning overlapping mask for partial-to-partial point cloud registration[C]. IEEE/CVF International Conference on Computer Vision, Montreal, Canada, 2021 : 3112 – 3121.
- [23] CHARLES R Q, SU H, KAICHUN M, et al. PointNet: Deep learning on point sets for 3D classification and segmentation[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Honolulu, USA, 2017 : 77 – 85.
- [24] QI R, YI L, SU H, et al. Pointnet++: Deep hierarchical feature learning on point sets in a metric space[J]. Advances in Neural Information Processing Systems, 2017, 30 : 5099 – 5108.
- [25] YEW Z J, LEE G H. 3DFeat-Net: Weakly supervised local 3D features for point cloud registration[C]. European Conference on Computer Vision, Munich, Germany, 2018 : 630 – 646.
- [26] GOJCIC Z, ZHOU C, WEGNER J D, et al. The Perfect Match: 3D Point Cloud Matching With Smoothed Densities[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, USA, 2019 : 5540 – 5549.
- [27] WANG Y, SUN Y, LIU Z, et al. Dynamic graph cnn for learning on point clouds[J]. Acm Transactions On Graphics, 2019, 38(5) : 1 – 12.
- [28] THOMAS H, QI C R, DESCHAUD J-E, et al. KPConv: Flexible and deformable convolution for point clouds[C]. IEEE/CVF International Conference on Computer Vision, Seoul, Korea, 2019 : 6410 – 6419.
- [29] ZENG A, SONG S, NIEßNER M, et al. 3DMatch: Learning local geometric descriptors from RGB-D reconstructions[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Honolulu, USA, 2017 : 199 – 208.
- [30] CHOY C, PARK J, KOLTUN V. Fully convolutional geometric features[C]. IEEE/CVF International Conference on Computer Vision, Seoul, Korea, 2019 : 8957 – 8965.

- [31] AO S, HU Q, YANG B, et al. Spinnet: Learning a general surface descriptor for 3d point cloud registration[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, virtual, 2021 : 11753 – 11762.
- [32] BAI X, LUO Z, ZHOU L, et al. D3Feat: Joint learning of dense detection and description of 3D local features[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle, USA, 2020 : 6358 – 6366.
- [33] HUANG S, GOJCIC Z, USVYATSOV M, et al. PREDATOR: Registration of 3D point clouds with low overlap[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, virtual, 2021 : 4265 – 4274.
- [34] BAI X, LUO Z, ZHOU L, et al. PointDSC: Robust point cloud registration using deep spatial consistency[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, virtual, 2021 : 15854 – 15864.
- [35] WANG Y, SOLOMON J. Deep Closest Point: Learning representations for point cloud registration[C]. IEEE/CVF International Conference on Computer Vision, Seoul, Korea, 2019 : 3522 – 3531.
- [36] LI J, ZHANG C, XU Z, et al. Iterative distance-aware similarity matrix convolution with mutual-supervised point elimination for efficient point cloud registration[C]. European Conference on Computer Vision, Glasgow, UK, 2020 : 378 – 394.
- [37] CHOY C, DONG W, KOLTUN V. Deep global registration[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle, USA, 2020 : 2511 – 2520.
- [38] MIN T, SONG C, KIM E, et al. Distinctiveness oriented positional equilibrium for point cloud registration[C]. IEEE/CVF International Conference on Computer Vision, Montreal, Canada, 2021 : 5490 – 5498.
- [39] LI Q, HAN Z, WU X-M. Deeper Insights into Graph Convolutional Networks for Semi-Supervised Learning[C]. Proceedings of the AAAI Conference on Artificial Intelligence, New Orleans, USA, 2018 : 3538 – 3545.
- [40] CHEN D, LIN Y, LI W, et al. Measuring and relieving the over-smoothing problem for graph neural networks from the topological view[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(04) : 3438 – 3445.

- [41] FISCHLER M A, BOLLES R C. Random sample consensus: a paradigm for model fitting with applications to image analysis and automated cartography[J]. Communications of the ACM, 1981, 24(6) : 381–395.
- [42] CHOY C, GWAK J, SAVARESE S. 4d spatio-temporal convnets: Minkowski convolutional neural networks[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019 : 3075–3084.
- [43] MILIOTO A, VIZZO I, BEHLEY J, et al. Rangenet++: Fast and accurate lidar semantic segmentation[C]. 2019 IEEE/RSJ international conference on intelligent robots and systems (IROS), 2019 : 4213–4220.
- [44] AJAKAN H, GERMAIN P, LAROCHELLE H, et al. Domain-adversarial neural networks[J]. arXiv preprint arXiv:1412.4446, 2014.
- [45] XIAO A, HUANG J, GUAN D, et al. Transfer learning from synthetic to real lidar point cloud for semantic segmentation[C]. Proceedings of the AAAI conference on artificial intelligence : Vol 36, 2022 : 2795–2803.
- [46] PAN Y, GAO B, MEI J, et al. Semanticposs: A point cloud dataset with large quantity of dynamic instances[C]. 2020 IEEE Intelligent Vehicles Symposium (IV), 2020 : 687–693.
- [47] BEHLEY J, GARBADE M, MILIOTO A, et al. Semantickitti: A dataset for semantic scene understanding of lidar sequences[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2019 : 9297–9307.
- [48] CAESAR H, BANKITI V, LANG A H, et al. nuscenes: A multimodal dataset for autonomous driving[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020 : 11621–11631.
- [49] YUAN Z, ZENG W, SU Y, et al. Density-guided Translator Boosts Synthetic-to-Real Unsupervised Domain Adaptive Segmentation of 3D Point Clouds[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024 : 23303–23312.
- [50] WANG D, SHANG Y. A new active labeling method for deep learning[C]. 2014 International joint conference on neural networks (IJCNN), 2014 : 112–119.

- [51] ROTH D, SMALL K. Margin-based active learning for structured output spaces[C]. Machine Learning: ECML 2006: 17th European Conference on Machine Learning Berlin, Germany, September 18-22, 2006 Proceedings 17, 2006 : 413 – 424.
- [52] SETTLES B. Active learning literature survey[J], 2009.
- [53] NING M, LU D, WEI D, et al. Multi-anchor active domain adaptation for semantic segmentation[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021 : 9112 – 9122.
- [54] HUANG D, LI J, CHEN W, et al. Divide and adapt: Active domain adaptation via customized learning[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2023 : 7651 – 7660.
- [55] SU J-C, TSAI Y-H, SOHN K, et al. Active adversarial domain adaptation[C]. Proceedings of the IEEE/CVF winter conference on applications of computer vision, 2020 : 739 – 748.
- [56] PRABHU V, CHANDRASEKARAN A, SAENKO K, et al. Active domain adaptation via clustering uncertainty-weighted embeddings[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2021 : 8505 – 8514.
- [57] XIE B, YUAN L, LI S, et al. Active learning for domain adaptation: An energy-based approach[C]. Proceedings of the AAAI conference on artificial intelligence : Vol 36, 2022 : 8708 – 8716.
- [58] XIE B, LI S, GUO Q, et al. Annotator: A generic active learning baseline for lidar semantic segmentation[J]. Advances in Neural Information Processing Systems, 2023, 36.
- [59] WELFORD B P. Note on a method for calculating corrected sums of squares and products[J]. Technometrics, 1962, 4(3) : 419 – 420.
- [60] CHEN S, JIA X, HE J, et al. Semi-supervised domain adaptation based on dual-level domain mixing for semantic segmentation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021 : 11018 – 11027.
- [61] WANG Y, YIN J, LI W, et al. Ssda3d: Semi-supervised domain adaptation for 3d object detection from point cloud[C]. Proceedings of the AAAI Conference on Artificial Intelligence : Vol 37, 2023 : 2707 – 2715.

- [62] GAO Y, LI J, ZHOU Y, et al. Optimization methods for large-scale machine learning[C]. 2021 18th International Computer Conference on Wavelet Active Media Technology and Information Processing (ICCWAMTIP), 2021 : 304 – 308.
- [63] XIAO A, HUANG J, GUAN D, et al. Polarmix: A general data augmentation technique for lidar point clouds[J]. Advances in Neural Information Processing Systems, 2022, 35 : 11035 – 11048.
- [64] SALTORI C, GALASSO F, FIAMENI G, et al. Cosmix: Compositional semantic mix for domain adaptation in 3d lidar segmentation[C]. European Conference on Computer Vision, 2022 : 586 – 602.
- [65] WANG F, HAN Z, ZHANG Z, et al. Mhpl: Minimum happy points learning for active source free domain adaptation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023 : 20008 – 20018.
- [66] XIE M, LI Y, WANG Y, et al. Learning distinctive margin toward active domain adaptation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022 : 7993 – 8002.
- [67] SCHACHTSIEK M, ROSSI S, HANNAGAN T. Class Balanced Dynamic Acquisition for Domain Adaptive Semantic Segmentation using Active Learning[J]. arXiv preprint arXiv:2311.14146, 2023.
- [68] NEKRASOV A, SCHULT J, LITANY O, et al. Mix3d: Out-of-context data augmentation for 3d scenes[C]. 2021 international conference on 3d vision (3dv), 2021 : 116 – 125.

## 作者简介

### 1. 攻读学位期间的研究成果

#### (一) 发表的学术论文和著作

[1] 第 2 作者 (导师为第 1 作者) . IEEE Transactions on Circuits and Systems for Video Technology.(在投)

#### (二) 申请 (授权) 专利

[1] 第 2 作者 (导师为第 1 作者) . 2023.01.29.

[2] 第 2 作者 (导师为第 1 作者) . 2023.02.24.

#### (三) 参与的科研项目及获奖

致 谢

---

## 致 谢